




Universitatea Naţională de Știință și Tehnologie Politehnica București
Facultatea de Automatică și Calculatoare
Departamentul de Automatică şi Ingineria Sistemelor

LUCRARE DE DIPLOMĂ

Metode de preprocesare și învățare nesupervizată pentru analiza semnalelor electroencefalografice

Absolvent
Maria-Daria Bălăucă

Coordonator
Conf. dr. ing. Andra-Elena Băltoiu

Bucureşti, 2026

Cuprins

1 Introducere **1**

2 Definirea problemei **2**
2.1 Scopul . . . 2

3 Soluții existente **4**
3.1 Analiza semnalelor EEG în contexte afective și de conștiență . . . 4
3.2 Preprocesarea semnalelor EEG . . . 4
3.2.1 Filtrarea trece-bandă (band-pass) . . . 4
3.2.2 Filtrarea Notch . . . 5
3.2.3 Baseline correction . . . 5
3.2.4 Re-referențierea semnalelor . . . 5
3.2.5 Eliminarea artefactelor prin Analiza Componentelor Independente (ICA) 5
3.3 Segmentarea semnalelor EEG . . . 5
3.4 Extragerea caracteristicilor . . . 6
3.4.1 Domeniul temporal . . . 6
Caracteristici bazate pe ERP . . . 6
3.4.2 Caracteristici în domeniul frecvență . . . 6
3.4.3 Caracteristici complexe . . . 7
3.5 Reducerea dimensionalității și selecția caracteristicilor . . . 7
Algoritmi evolutivi . . . 7
3.6 Metode de clusterizare . . . 7
3.6.1 K-Means . . . 7
3.6.2 K-medoids, cu distanța Dinamyc Time Wraping (DTW) . . . 8
3.6.3 Metoda Ward . . . 8
3.6.4 Modelele de Mixtură Gaussiană (GMM) . . . 8
3.7 Bazele recunoașterii emoțiilor prin intermediul semnalelor EEG . . . 8
3.7.1 Reprezentarea emoțiilor: modelul Valență-Stimulare . . . 8
3.8 Provocări și limitări în analiza răspunsurilor corticale pe baza semnalelor EEG . 9

4 Metodologia de achiziție a datelor **10**
4.1 Studiul 1 - Analiza răspunsului cortical la stimuli vizuali afectiv . . . 10
4.2 Studiul 2 - Analiza dinamicii activității cerebrale în condiții de alterare farmacologică a stării de conștiență . . . 11

5 Soluția propusă **13**
5.1 Studiu 1 . . . 13
5.1.1 Segmentarea datelor . . . 13
5.1.2 Eliminarea zgomotului prin ICA (Independent component analysis) . . . 13
5.1.3 Preprocesarea semnalului . . . 14
5.1.4 Extragerea caracteristicilor (Features extraction) . . . 15
5.1.5 Clusterizare . . . 15
Clusterizare bazată pe semnalele continue . . . 15
Clusterizarea bazată pe caracteristicile extrase - metoda K-means . . . 16
Clusterizarea DBSCAN (Density based spatial clustering of applications with noise . . . 16

Clusterizarea pe regiuni corticale . . . 16
Clusterizarea cu categoriile colapsate (N -> L) . . . 17
5.1.6 Interfață creier-calculator (Brain-Computer Interface - BCI) . . . 17
Conectarea și sincronizarea datelor în timp real . . . 17
Analiza în timp real . . . 17
5.2 Studiu 2 . . . 18
5.2.1 Segmentare . . . 18
5.2.2 Preprocesare . . . 18
5.2.3 Matricea TSP (Putere spectrală topografică) și Reducerea dimensionalității prin PCA . . . 18
5.2.4 Comparație algoritmi de clusterizare (K-Means vs. Ward vs. GMM) . . . 19
5.2.5 Determinarea numărului de macrostări (k) . . . 19
5.2.6 Standardizarea macrostărilor . . . 20
5.2.7 Analiza macrostărilor prin ocupanță . . . 20
5.2.8 Identificare macrostare implicită . . . 20
5.2.9 Interpretare rezultate prin regresie liniară . . . 21

6 Rezultate și Discuții **22**
6.1 Studiul 1 - Analiza răspunsului cortical la stimuli vizuali afectiv . . . 22
Vizualizare epoci semnal continuu . . . 22
Testare algoritmi de clusterizare pe semnalul continuu . . . 22
6.1.1 Clusterizarea bazată pe caracteristici extrase . . . 25
Algoritmul DBSCAN . . . 27
6.1.2 Variante de optimizare a clusterizării . . . 28
6.1.3 BCI . . . 30
Conectarea și sincronizarea datelor în timp real . . . 30
Analiza în timp real . . . 31
6.1.4 Discuții finale . . . 33
6.2 Studiul 2 - Analiza dinamicii activității cerebrale în condiții de alterare farmacologică a stării de conștiență . . . 33
6.2.1 Reprezentarea spațio-frecvențială și analiza globală . . . 33
6.2.2 Determinare număr optim de clustere k . . . 34
6.2.3 Comparație Algoritmi: K-Means vs. Ward . . . 35
6.2.4 Comparație reactivitate stare DEM pentru înregistrări individuale . . . 37
6.2.5 Analiză prin Regresie liniară . . . 38
6.2.6 Discuții finale . . . 39

7 Concluzii **41**
7.1 Direcții viitoare . . . 42
7.2 Concluzii generale . . . 42

8 Lista contribuțiilor personale **43**

1 Introducere

Una dintre cele mai utilizate metode non-invazive de a investiga dinamica corticală constă în înregistrarea și analiza semnalelor electroencefalografice (EEG). Acest fapt este datorat rezoluției temporale ridicate a acestei metode și a posibilității de captare a răspunsului cortexului asociat cu diferite evenimente, în diverse contexte experimentale.

În ultimii ani, creșterea interesului pentru dezvoltarea de metode automate care analizează datele EEG a fost semnificativă în ultimii ani, întrucât analiza exclusiv umană nu poate face față complexității ridicate a semnalelor și cantității mari de informații. În plus, variabilitatea datelor de la un subiect la altul (inter-subiect), dar și a înregistrărilor aceluiași subiect la momente diferite de timp (intra-subiect), cât și prezența zgomotelor și a artefactelor îngreunează cu atât mai mult analiza pe acest tip de date. De aceea, este esențială dezvoltarea unor metode automate, capabile să identifice tiparele apărute la nivelul semnalelor, astfel permițând investigarea răspunsurilor corticale într-un mod cât mai obiectiv.

Domeniile principale în care acestă metodă are aplicații sunt medicina și neuroștiințele. Însă o astfel de abordare poate fi utilă în domenii variate, care la prima vedere nu au legătură directă cu activitatea cerebrală. Spre exemplu, domeniile care implică interacțiunea om-calculator pot beneficia de rezultatele obținute prin analiza obiectivă a unor răspunsuri corticale înregistrate fie înainte, fie chiar în timpul utilizării aplicației.

Mai exact, în momentul de față modelele de inteligență artificială pot genera o multitudine de variante pentru cerințele utilizatorului, însă apare astfel dilema a ce ar fi cel mai potrivit să aleagă ca variantă finală, fiind atât de multe opțiuni. Ceea ce lipsește dintr-o abordare strict bazată pe descrieri conceptuale este o modalitate de a face modelul generator să înțeleagă ce ar trebui să transmită sau să trezească la nivel emoțional rezultatul generat pentru utilizator. În acest sens, o modalitate de a adăuga noua dimensiune este utilizarea unui model antrenat pentru detectarea și clusterizare emoțiilor, într-o manieră obiectivă, bazată pe răspunsul automat al creierului. Un exemplu concret în acest sens este domeniul arhitecturii, în care este foarte dificilă descrierea în cuvinte de către arhitect, și apoi înțelegerea de către un generator automat, a emoțiilor și sentimentelor pe care ar trebui să le transmită o construcție. Însă, prin adăugarea acestui strat suplimentar de informație, modelul generator poate deveni mult mai specific și poate oferi rezultate mult mai apropiate de intențiile și viziunea inițială a arhitectului.

În același timp, prin intermediul datele EEG se pot investiga fenomene fundamentale pentru funcționarea creierului, din punct de vedere biologic sau medical. Spre exemplu, poate fi studiată dinamica pentru diferite nivele de conștiență sau modul în care creierul răspunde în aceste condiții la stimulii externi. Înțelegerea acestor mecanisme reprezintă un pas fundamental în dezvoltarea unor metode de monitorizare a stărilor în care se află subiecții.

Astfel, analiza semnalelor EEG reprezintă un domeniu de interes, aflat în continuă dezvoltare, utilizat atât în cadrul aplicațiilor practice, cât și a înțelegerii proceselor neurofiziologice. În acest sens, lucrarea de față are ca scop investigarea unor metode de analiză a semnalelor EEG. Structura se bazează pe mai multe capitole, începând cu definirea problemei și a obiectivelor, descrierea soluțiilor deja existente în literatură și prezentarea a două paradigme experimentale. Se continuă cu descrierea soluțiilor propuse și implementarea acestora, împreună cu ilustrarea și interpretarea rezultatelor obținute. În final, sunt discutate conlcuziile lucrării și direcțiile viitoare posibile.

2 Definirea problemei

În contextul analizei de date EEG, se dorește ca datele colectate să fie utilizate într-o manieră care să permită diferențierea între anumite evenimente care au avut loc în timpul colectării de date. Această diferențiere nu este posibilă pe datele neprocesate, și în cele mai multe cazuri imposibilă doar prin analiza cu ochiul uman. Astfel, problema este de a găsi sau de a construi metode de procesare care să păstreze informațiile importante pentru analiza care se dorește a fi realizată ulterior. Indiferent de paradigma experiemntală sau de obiectivul final urmărit, analiza semnalelor EEG implică o succesiune de provocări: alegerea metodelor de preprocesare, împărțirea în funcție de epoci sau de trialuri a semnalelor, reprezentarea informației și extragerea anumitor caracteristici din semnal prin intermediul cărora să poată fi găsite tipare relevante care pot fi interpretate cu un anumit sens neurofizilogic.

Această problemă devine cu atât mai importantă în momentul în care se dorește o analiză în timp real, în baza unei Interfață creier-computer (*brain-computer interface* - BCI), pentru că atât preprocesarea, cât și modelele folosite pentru clusterizare trebuie să fie deja testate și eficiente pe date colectate offline, dar și să funcționeze destul de repede pentru a putea realiza toate calculele necesare în intervalul de timp dintre două evenimente.

2.1 Scopul

Interesul crescut din ultimii ani pentru sistemele bazate pe căști EEG duce către dezvoltarea unor abordări bazate pe acest tip de date pentru a înțelege și a utiliza rezultatele în numeroase domenii, atât din punct de vedere biologic, afectiv, cognitiv și nu numai. Această abordare a început să fie folosită la scară largă în domeniul decodării semnalelor corticale și în cazul Interfețelor Creier Computer (BCI - Brain Computer Interface), întrucât este oferită o metodă neivazivă de a înțelege dinamica creierului în experimente controlate.

Lucrarea de față se concentrează pe investigarea unor metode de analiză aplicate asupra semnalelor EEG în cadrul a două paradigme experimentale distincte, ambele bazate pe răspunsul cortical la stimuli vizuali. Alegerea de a analiza ambele studii în cadrul aceleiași lucrări permite evaluarea etapelor de preprocesare și analiză în condiții experimentale variate, pentru a investiga în ce măsură acest tip de date pot evidenția tipare relevante din punct de vedere fiziologic.

În primul studiu, contextul analizei semnalelor EEG este reprezentat de dezvoltarea unui sistem prin care să fie posibilă calibrarea unui generator de modele arhitecturale, prin intermediul răspunsului afectiv cortical al utilizatorului care evaluează în timp real rezultatele primite de la sistem. Pentru a se ajunge însă în acel punct, analiza inițială este bazată pe date EEG colectate offline, cu stimuli vizuali reprezentați de imagini normale, nu arhitecturale, care sunt menite să stimuleze emoțional subiectul. Astfel, se dorește a se găsi o modalitate de a corela răspunsul cortical obiectiv cu tipul de stimuli primiți de către subiect. Apoi, într-o manieră asemănătoare, se dorește același tip de analiză, însă cu stimuli vizuali de natură arhitecturală. Sistemul final va fi bazat pe folosirea unei BCI în timp real, însă toate etapele până în punctul final sunt la fel de importante, printre provocările inițiale numărându-se achiziția de date, organizarea, preprocesarea și analiza offline a datelor, acești pași fiind baza necesară a dezvoltării unui sistem de decodificare și calibrare în timp real.

În al doilea studiu, atenția cade asupra unor înregistrări EEG colectate de la subiecți de regn animal, anume șobolani, care se află în stări de conștiență diferite, induse în mod farmacologic. Scopul studiului este de a explora dinamica creierului în condiții controlate asupra nivelului de conștiență al animalului, dar și prin intermediul unor stimuli vizuali controlați. Ideea de bază este de a ajunge la o metodă de analiză simplificată, prin care să fie posibilă evaluare nivelului de conștiență a unui subiect printr-o metodă non-invazivă. Din acest motiv, analiza este realizată pe un singur canal EEG, adică utilizând informația provenită de la un singur electrod. Acest tip de analiza a stărilor de conștiință a fost realizat și anterior în literatura de specialitate [15, 18, 11]. Lucrarea acuală urmărește în principal aceeași paradigmă de analiză ca cea descrisă în [12], datele analizate fiind aceleași. Ce o diferențiază însă este faptul ca accentul este pus pe componenta tehnică, obiectivul constând în analiza și evaluarea diferitelor metode posibile de procesare, pentru a identifica o soluție optimă pentru configurarea unui pipeline automat de analiză. În acest sens, sunt investigate și comparate mai multe abordări, pentru a determina algoritmii și parametrii care oferă cele mai bune rezultate pentru cerință. Studiul actual este desfășurat pe șobolani, condițiile experimentale permițând controlul direct al nivelului de conștiență al subiecților. Cu toate acestea, direcția finală urmărită este de a extinde această abordare și către subiecți umani, prin dezvoltarea unei metode cât mai simple și mai ușor de aplicat în practică.

Astfel, prin procesarea și analiza ambelor seturi de date, prin această lucrare se urmărește investigarea unor metode de preprocesare, reprezentare și identificare a unor tipare corticale relevante. Deși cele două studii au paradigme experimentale diferite, acestea au la bază aceeași problemă fundamentală, și anume transformarea semnalelor EEG brute într-o formă care să permită evidențierea unor relații și structuri relevante din punct de vedere neurofiziologic. Scopul principal este de a oferi o analiză din mai multe perspective asupra înțelegerii și analizării stărilor cerebrale, în baza datelor EEG și de a investiga modul în care alegerea etapelor de preprocesare, reprezentare și clusterizare influențează rezultatele obținute în contexte experimentale diferite.

3 Soluții existente

3.1 Analiza semnalelor EEG în contexte afective și de conștiență

Electroencefalograma (EEG) reprezintă o metodă non-invazivă de măsurare a activității electrice a creierului, cu o rezoluție temporală ridicată, oferind informații valoroase pentru analiza proceselor care se întâmplă la nivel cortical [3].

În general, analiza proceselor corticale din EEG se lovește la început de anumiți factori cum ar fi zgomotul semnalului, dar și variabilitatea, atât între subiecți, cât și în momentele de colectare a datelor pentru același subiect. Astfel, generalizarea modelelor de la un individ la altul devine uneori dificilă, însă tehnici precum curățarea etichetelor, selecția datelor, dar și metode de adaptare și de învățare prin transfer pot îmbunătăți robustețea sistemelor [3]. În plus, direcțiile principale care sunt abordate în analiză sunt fie prin orientare către domeniul frecvență [5, 15], prin densitatea spectrală de putere, fie către cel temporal [5], bazat pe potențialele evocate (ERP), însă în ambele variante revine problema alegerii trăsăturilor celor mai definitorii pentru modul în care s-au colectat datele, tipul de stimuli și rezultatul așteptat. În ciuda acestor provocări, există un progres constant în domeniul analizei EEG, dezvoltându-se sisteme din ce în ce mai potrivite pentru cerințele fiecărui proiect.

3.2 Preprocesarea semnalelor EEG

Un semnal EEG brut, neprocesat, este foarte influențat de zgomotul generat de mișcarea musculară, clipit, variațiile de contact dintre electrozi și scalp etc. De aceea, înainte de orice analiză, pașii de preprocesare sunt absolut necesari, reușind să îmbunătățească raportul semnal-zgomot și să rămână în evidență informațiile relevante [5, 19, 3].

3.2.1 Filtrarea trece-bandă (band-pass)

Filtrarea trece-bandă de tip Butterworth este printre cele mai utilizate proceduri, permițând trecerea componentelor semnalului situate între două frecvențe limită și atenunându-le pe cele aflate în afara intervalului. Astfel, se pot păstra exclusiv componentele care au o frecvență relevantă pentru activitatea corticală, fiind eliminat zgomotul de înaltă frecvență, dar și variațiile foarte lente.

Intervalul de filtrare utilizat variază în funcție de obiectivul studiului, existând mai multe exemple: 0.5-40 Hz [4], 1-30 Hz [8, 15, 18], 1-35 Hz [11], 1-48 Hz [3].

Pentru analiza ERP, în general limita superioară este mai redusă, informația relevantă fiind mai mult la frecvențele mai joase [6, 8].

3.2.2 Filtrarea Notch

Semnalele EEG sunt de asemenea afectate de interferențe din rețeaua electrică a aparaturii folosite, care apare în jurul frecvenței de 50 Hz, putând acoperi informații relevante. Pentru eliminarea acestei componente se utilizează filtre de tip notch care atenuează o bandă îngustă de frecvențe, centrată în jurul valorii date, permițând păstrarea majorității componentelor semnalului [4, 19, 3].

3.2.3 Baseline correction

Baseline correction este utilizat în special în analiza care se concentrează pe ERP. Scopul principal este standardizarea răspunsurilor între diferite trial-uri. Ferestrele variază între 100 și 500 ms înainte de stimulul [4, 3, 6, 8].Se calculează valorea medie a semnalului dintr-o perioadă temporală de dinainte de stimulul și se scade din toată epoca.

3.2.4 Re-referențierea semnalelor

În cadrul EEG, măsurătorile sunt bazate pe diferențele de potențial electric, deci electrodul de referință influențează semnalul. O metodă utilizată frecvent este re-referențierea, în care semnalul de la fiecare canal este recalculat prin scăderea mediei tuturor electrozilor [3, 15, 18]. De asemenea, se mai folosește utilizarea electrodului Cz ca referință [1]. Astfel, compararea activității între diferite regiuni corticale este facilitată.

3.2.5 Eliminarea artefactelor prin Analiza Componentelor Independente (ICA)

Unul dintre cei mai importanți pași în preprocesare este eliminarea artefactelor, care provin cel mai des de la clipit, mișcările ochilor, activitatea musculară, mișcările capului.

ICA este printre cele mai folosite metode pentru eliminarea acestor surse de zgomot [5, 19, 1]. Metoda se bazează pe ipoteza că semnalul EEG este o combinație liniară a mai multor componente independente statistic, pe care algoritmul încearcă să le separe. Apoi, aceste componente care sunt asociate artefactelor sunt identificate și eliminate, iar semnalul este reconstruit doar din componente considerate relevante din punct de vedere neuronal. Mai multe studii punctează apariția unor îmbunătățiri asupra performanței clusterizărilor după aplicarea ICA [5, 19].

3.3 Segmentarea semnalelor EEG

După preprocesare, semnalele EEG continue sunt împărțite în segmente temporale numite epoci. Fiecare epocă este separată prin asocierea unui stimul/eveniment, reprezentând segmentul de bază utilizat ulterior în analiză.

Durata epocilor diferă în funcție de metodologia studiului. În cadrul analizelor bazate pe ERP, sunt utilizate în general ferestre care includ atât o perioadă pre-stimul, cât și una post-stimul: -100 ms și 1000 ms [6], -300 ms și 1000 ms [19] sau doar o fereastră de 1 secundă calculată de la apariția stimulului [8].

Astfel, prin segmentare este posibilă evaluarea răspunsului cerebral asociat fiecărui stimul, iar tehnicile de analiză pot fi aplicate pentru fiecare trial în parte.

3.4 Extragerea caracteristicilor

De multe ori, din semnalul EEG sunt extrase anumite caracteristici relevante pentru tipul de stimul analizat, având ca bază teoretică partea fiziologică deja cunoscută.

3.4.1 Domeniul temporal

Caracteristicile temporale includ informații numerice precum media, deviația standard, amplitudinea maximă/minimă, latența anumitor evenimente [5]. Acestea sunt relativ simplu de calculat și oferă performanțe inferioare față de alte metode.

Caracteristici bazate pe ERP

Printre componentele analizate frecvent în cazul răspunsurilor emoționale se numără N100, un vârf negativ care apare aproximativ la 80–120 ms post-stimul, asociat procesării senzoriale timpurii, și P300, un vârf pozitiv care apare la 250–500 ms, asociat procesării cognitive [4]. Totodată, sunt utilizate EPN (Early Posterior Negativity, componentă negativă prezentă între 150-300 ms, reprezentând răspunsul timpuriu în zona occipito-parietală, asociat atenția selectivă către stimuli) și LPP (Late Positive Potential, componentă pozitivă prezentă între 400-1000 ms, reflectând procesarea ulterioară a răspunsului emoțional [6].Astfel, se calculează amplitudinea și latența, în ferestre temporale specifice.

Analiza ERP-urilor este foarte eficientă în cazul diferențierii nivelului de stimulare, chiar și atunci când diferențele de valență nu sunt la fel de clare sau ușor detectabile [8].

3.4.2 Caracteristici în domeniul frecvență

Caracteristicile spectrale reprezintă altă categorie utilizată frecvent în clusterizarea semnalelor EEG, bazată pe distribuției puterii semnalului în diferite benzi de frecvență. Adesea analiza se bazează pe densitatea spectrală de putere (PSD - Power Spectral Density), calculată prin Fast Fourier Transform (FFT) sau Short Time Fourier Transform (STFT) [5]. Transformata discretă Fourier este definită ca:

$$X(k) = \sum_{n=0}^{N-1} x(n) e^{-j2\pi kn/N} \tag{3.1}$$

unde $x(n)$ reprezintă semnalul în domeniul temporal, iar $X(k)$ amplitudinea asociată frecvenței k. Densitatea spectrală de putere se obține apoi ca:

$$PSD(f) = \frac{|X(f)|^2}{N} \tag{3.2}$$

În cazul STFT, calculul este bazat pe formula:

$$STFT\{x(t)\}(m,\omega) = \sum_{n=-\infty}^{\infty} x(n) w(n-m) e^{-j\omega n} \tag{3.3}$$

unde $w(n)$ reprezintă funcția de fereastră utilizată.

După calculul PSD, se poate determina puterea semnalului pentru fiecare bandă de frecvență de interes - theta (4-8 Hz), alfa (8-13 Hz), beta (13-30 Hz), gamma (peste 30 Hz). Apariția unor modificări în aceste benzi au fost asociate în mod repetat cu diferite răspunsuri emoționale și cognitive.

Pe baza caracteristicilor spectrale, se poate construi, prin calculul PSD pentru ferestre temporale succesive, o reprezentare timp-frecvență a puterii spectrale, numită matrice Time-Frequency Spectral Power (TSP). Această reprezentare poate fi utilizată în analiza variațiilor la nivel cortical.

3.4.3 Caracteristici complexe

Pe lângă metodele enumerate mai sus, recent au fost utilizate și caracteristici mai complexe, precum entropia diferențială (calculează imprevizibilitatea semnalului), dimensiunea fractală (complexitatea/neregularitatea formei semnalului), indicele de asimetrie emisferică (diferențe între activitatea emisferei stângi vs drepte) și valorile de sincronizare de fază (sincronizate oscilațiilor din două regiuni separate) [5]. Aceste caracteristici încearcă să surpindă relații neliniare sau modele de comunicare sincronizată între regiuni corticale.

3.5 Reducerea dimensionalității și selecția caracteristicilor

Deoarece în general se lucrează cu multe canale și cu multe trăsături extrase pentru fiecare epocă, acest lucru poate duce la supraînvățare și la mărirea costului computațional. Pentru evitarea acestor cazuri, adesea sunt folosite metode de selecție sau de reducere a dimensionalității. Cele mai întâlnite metode în domeniul EEG sunt Analiza componentelor principale (PCA) [12, 11], Neighbourhood component analysis (NCA) și algoritmii genetici [5, 8].

Algoritmi evolutivi

Algoritmii evolutivi, în general cei genetici, reprezintă o metodă de selecție des folosită. Ideea de bază este că se uită la fiecare subset de trăsături extrase ca la un individ dintr-o populație și încearcă să găsească combinația optimă pentru cerința studiului [5].

3.6 Metode de clusterizare

Rolul metodelor de clusterizare în analiza EEG este predominant de a explora și înțelege structura datelor și variabilitatea intra/inter daatelor de la participanți. Astfel, se pot identifica tipare și modul în care se aseamănă/se grupează caracteristicile [5, 3].

3.6.1 K-Means

În analiza EEG, K-Means este una dintre cele mai utilizate metode de clusterizare, putând fi aplicat pe caracteristicile extrase/selectate,identificând epoci cu răspunsuri corticale similare. În general, metoda este eficientă din punct de vedere computațional, însă necesită alegerea prealabilă a numărului de clustere, fiind de asemenea destul de sensibilă la valori extreme.

3.6.2 K-medoids, cu distanța Dinamyc Time Wraping (DTW)

K-medois este o metodă similară cu K-means, însă fiecare cluster este reprezentat de un punct real din date. Această metodă permite utilizarea metricii de distanță Dynamic Time Warping (DTW) [9], care nu se bazează strict pe alinierea punct cu punct dintre două serii temporale. Astfel, aceasta permite alinierea între două secvențe de timp, maximizând similaritatea dintre formele generale ale semnalelor. Două semnale cu aceeași structură, dar ușor decalate temporal, au o distanță mai scăzută.

3.6.3 Metoda Ward

Metoda Ward este o metodă ierarhică ce inițial vede fiecare punct ca pe un cluster separat și le unește treptat în funcție de care sunt cele mai asemănătoare; la fiecare pas, se aleg clusterele a căror fuziune duce la cea mai mică creștere a variabilității interne din grupuri, până când numărul grupurilor este egal cu cel impus de dinainte

3.6.4 Modelele de Mixtură Gaussiană (GMM)

Metoda GMM este o metodă probabilistică în care fiecare entitate este asociată cu o probabilitate de apartenență față de fiecare cluster, permițând identificarea unor clustere cu forme diferite, oferind o reprezentare mai flexibilă a datelor

3.7 Bazele recunoașterii emoțiilor prin intermediul semnalelor EEG

Cu ajutorul măsurării activității cerebrale, bazată pe variațiile potențialului electric la nivelul scalpului, emoțiile pot fi analizate din punct de vedere obiectiv [5, 4]. Astfel, recunoașterea automată a emoțiilor pe baza semnalelor EEG este la intersecția interdisciplinară dintre neuroștiințe, procesarea semnalelor și învățare automată. Acest fel de detectare a emoțiilor are și implicații practice directe în cadrul sistemelor adaptive și/sau interactive. Un studiu recent demonstrează acest potențial aplicativ în cadrul unui sistem neuroadaptiv pentru proiectarea arhitecturală. Astfel, bazându-se pe BCI, crearea și adaptarea acestor modele generate se bazează și pe răspunsurile afective automate ale privitorilor [19].

3.7.1 Reprezentarea emoțiilor: modelul Valență-Stimulare

Pentru ca detectarea automată a emoțiilor să poată funcționa, este necesară o reprezentare ușor de înțeles de către computer. Una dintre abordările standard este de a le vizualiza prin intermediul unui modelul bidimensional Valență (se referă la gradul de plăcere/neplăcere al unei emoții) și Stimulare (nivelul de activare asociat acesteia). Studiile care au la bază stimuli vizuali standardizați, cum ar fi IAPS, utilizează frecvent acest model [4]. Astfel, emoțiile precum fericirea/entuziasmul sunt caracterizate prin valență pozitivă și stimulare ridicată, în timp ce tristețea, frica au valență negativă și niveluri variabile de stimulare.

3.8 Provocări și limitări în analiza răspunsurilor corticale pe baza semnalelor EEG

Analiza datelor EEG rămâne în continuare o problemă dificilă, în cadrul căreia este necesară încercarea și dezvoltare de metode. Sunt evidențiate patru limitări repetate în mai multe cercetări:

- variabilitatea intra-subiect, întrucât răspunsurile pot varia chiar și în aceeași sesiune de colectare a datelor pentru un singur subiect, din cauza oboselii, a nivelului de atenție, sau uneori a condițiilor în care se desfășoară colectarea [5].

- variabilitatea inter-subiect, din pricina căreia modelele și analizele desfășurate în baza datelor de la un anumit subiect să nu se poate generaliza direct și către alți subiecți, având nevoie de adaptare [5, 4, 3]

- găsirea unui echilibru între cât de complex este modelul de analiză și cât de generalizabil este - astfel, cu toate că modelele foarte complexe au o performanță mai ridicată pe seturile pe care s-au antrenat, există riscul de a se concentra pe tipare prea specifice pentru anumiți participanți, devenind nepotrivite pentru seturi noi de date [5, 3]

- similaritatea dintre caracteristicile identificate pentru stimuli asemănători și imprecizia în momentul construirii etichetelor experimentale, în general din cauza subiectivității [5, 3, 8]

4 Metodologia de achiziție a datelor

Cadrul metodologic al lucării este alcătuit din două fluxuri independente, dar care au în comun structura bazată pe stimularea vizuală a subiecților și înregistrarea semnalelor EEG. Astfel, un punct foarte important este aliniarea temporală exactă între stimulii prezentați și răspunsurile corticale colectate, pentru ca semnalele EEG continue să poată fi segmentate în epoci pe care va fi aplicată analiza apoi.

4.1 Studiul 1 - Analiza răspunsului cortical la stimuli vizuali afectiv

În primul studiu datele EEG sunt colectate prin intermediul unui sistem EEG ANT Neuro cu 64 de canale [2]. În total au fost 10 participanți, înscrierea acestora la studiu fiind voluntară, eșantionarea fiind de tip convenienț̦ă.

Cu toate că obiectivul final este dezvoltarea sistemului BCI de calibrare în timp real pe baza răspunsurilor corticale, această etapă are în vedere explicarea modului de achiziție a datelor pentru etapa inițială de dezvoltare a sistemului de analiză offline a răspunsului prin stimulii vizuali afectivi. Astfel, setul de date colectat inițial ține ca bază a dezvoltării finale.

Stimulii vizuali sunt compuși din 30 de imagini alese din cadrul unor stimuli afectivi standardizați, proveniți din International Affective Picture System (IAPS) [13]. Fiecare stimul are o durată de 1000 de ms, înainte și după acesta fiind afișată, pentru 500 de ms, o cruce de fixare.

Fiecare participant este supus la 50 de trialuri, fiecare trial conținând cele 30 de imagini, însă în ordine aleatorie, pentru a nu avea un efect de obișnuință. Fiecare stimul a fost etichetat înainte în baza a trei dimensiuni: valență, stimulare și dominanță, fiecare dintre aceste primind un nivel per imagine: scăzut (L - low), neutru (N - neutral), ridicat (H - high). Astfel, fiecare imagine are în final un cod. De exemplu, Figura **??** reprezintă una dintre imaginile folosite și are codificarea NHL, care înseamnă valență neutră, stimulare ridicată și dominanță scăzută.



Figura 4.1: Exemplu stimul vizual IAPS și fotografie din timpul desfășurării experimentului

Achiziția datelor a fost făcută prin înregistrarea unui semnal EEG continuu, în timp ce subiectul era expus la stimulii vizuali. Pentru facilitarea achiziției, înainte de colectare a fost utilizat un gel conductiv astfel încât contactul electrozilor să fie mai bun și pentru ca impedanța canalelor să fie mai redusă. Acest pas a asigurat o calitate mai bună și mai stabilă a semnalului colectat, pe tot parcursul experimentului. Pentru a avea o privire de ansamblu asupra studiului, inclusiv a părții de colectare a datelor, am participat și în calitate de subiect.

Pentru ca segmentarea epocilor să fie aliniate cu stimulii, este înregistrat și un document tip `.vmrk` în care sunt reținuti markerii de sincronizare, conținând detalii despre identificatorul markerului, tipul evenimentului, canalul, latența apariției, codul de identificare a stimulului, informarții suplimentare - exemplu de marker:

```
Mk5=Stimulus,s64,23174,1,0
```

Pentru a facilita diferențierea trialurilor, între fiecare dintre acestea sunt 5 stimuli vizuali scurți, de tip ecran alb, utilizați ulteorior pentru delimitarea robustă în epoci.

De asemenea, pentru fiecare participant există un document `Excel` cu ordinea celor 30 de imagini din fiecare trial.

4.2 Studiul 2 - Analiza dinamicii activității cerebrale în condiții de alterare farmacologică a stării de conștiență

În cel de-al doilea studiu, datele sunt colectate de la șobolani, cu o cască EEG care are două canale. Datele au fost primite printr-o colaborare cu Universitatea de Medicină și Farmacie ”Carol Davila” București. Subiecții aveau starea de conștiență alterată în mod farmacologic. În cadrul studiului este urmat protocolul descris în lucrarea [12], însă accentul este pus pe analiza și compararea diverselor variante de procesare, precum și dezvoltarea unui pipeline de analiză automatizat.

În total au fost analizate date de la un total de 19 șobolani. Setul de date se împarte în trei grupuri experimentale, în funcție de modul în care a fost aletartă stare de conștiență:

- 9 șobolani prin izofluran (ISO), date colectate în 2017
- 8 șobolani prin hidrat de cloral (CHL), date colectate în 2010/2011
- 2 șobolani care nu au fost supuși la niciuna dintre cele două substanțe, date colectate în 2024/2025

Subiecții au fost stimulați vizual prin stimulare luminoasă intermitentă (IPS - Intermittent photic stimulation), adică prin repetări al unui semnal vizual luminos. Numărul de trialuri variază între 20 și 40, în funcție de subiect. Fiecare trial are 30 de stimuli, care au o durată de 50 de milisecunde, separate între ele de o perioadă fără stimulare de 2 secunde. Unul dintre ochi este acoperit per trial pentru a se putea face analiza pe canalul ipsilateral stimulării, în cel contralateral fiind mai accentuat răspunsul automat generat de percepția stimului [11].

Înregistrările au fost primite în format Matlab `.mat`, în care se află o variabilă de tp `struct` cu următoarele câmpuri:

- `T0` - momentul de timp absolut în care a început trailul
- `trigs` - latența fiecărui stimul din trial, față de momentul inițial
- `TS` - vector de timp
- `eeg1` - semnalul EEG de pe canalul 1
- `eeg 2` - semnalul EEG de pe canalul 1
- `ok` - valoare binară, 1 dacă trailul poate fi inclus în analiză

5 Soluția propusă

5.1 Studiu 1

Soluția propusă pentru analiza răspunsurilor corticale ca urmare a unor stimuli afectivi este cea de clusterizare. Astfel, am încercat să găsesc metoda optimă prin care datele EEG să se împartă în categorii care să fie definite prin specificațiile stărilor afective produse de stimulii emoționali.

5.1.1 Segmentarea datelor

Primul pas și unul dintre cei fundamentali a fost împărțirea pe epoci a semnalului, și, mai ales, maparea fiecărei epoci cu imaginea folosită pentru stimulare. Această legătură nu a fost făcută direct, întrucât ordinea stimulilor era reținută separat într-un fișier `Excel`.

Astfel, semnalul este segmentat în baza unui fișier tip `vmrk`, pe baza căruia se filtrează și se iau în considerare doar markerii de tip "s64".

Pentru ca delimitarea dintre trialuri să fie mai clară, iar o greșeală de la un trial să nu perpetueze în analiza întregului set de date, între trialuri există acele cinci semnale luminoase scurte, menționate anterior. Astfel, aceștia sunt folosiți în procesul de segmentare: algoritmul caută în lista de stimulii o grupare care se diferențiază printr-o diferență mică de latență între doi stimuli consecutivi, care trebuie să fie mai mică decât `small_thresh = 0.2 * fs ms`. Ultimul stimul din această grupare este urmat de o pauză între `0.3 * fs ms` și `1.0 * fs ms`.

Doar după aceste validări, algoritmul caută exact 30 de stimuli consecutivi, cu condiția ca intervalul de timp dintre aceștia să fie minim textttlarge_thresh = 1.5 * fs. Există cazuri în care doi markeri descriu de fapt același stimul, aceștia fiind grupați. Se generează în final o matrice de dimensiune $30 \times N_{\text{seturi}}$, în care se regăsesc latențele la care apare fiecare stimul.

Pentru epocarea în sine, se taie semnalul în funcție de latențele găsite, astfel încât fereastra de timp să fie alcătuită din intervalul pre-stimulare, de 500 ms, și cel post-stimulare, de 1000 ms. Aceste intervale au fost alese astfel pentru a facilita analiza ERP și pe baza a altor rezultate din literatură [19].

După ce am făcut epocarea, a urmat etapa de mapare dintre epoci și stimulii pentru fiecare epocă. Astfel, am mapat imaginile din `Excel` în funcție de ordinea de acolo și de ordinea epocilor.

5.1.2 Eliminarea zgomotului prin ICA (Independent component analysis)

Cu toate că inițial am rulat anumite analize pe datele care nu au fost trecute prin ICA, am hotărât însă că este un pas important astfel încât analiza să nu fie influențată de zgomotele și artefactele de mișcare care apar inevitabil, mai ales din cauza duratei lungi a experimentului (aproximativ 50 de minute). Astfel, ICA a fost implementat pe o parte din date de către un

coleg din cadrul proiectului. Prin intermediul acestui tip de analiză, a putut să elimine zgomotul de amplitudine mare provenit de la clipit, mișcări oculare sau musculare, care făcea anumite epoci să fie redundante în analiză, sau chiar să afecteze în mod negativ.

Însă această eliminare a dus la o discontinuitate în semnalul inițial, marcate de bucăți numite `boundary`, care reprezintă o latență, fiind schimbate și latențele din fișierul `vmrk`. Pentru a rezolva această problemă, care ducea la o incongruență între stimuli și răspunsurile corticale înregistrate, pentru datele precesate de colegul meu, am propus și am implementat o metodă bazată pe un id al evenimentului care era același și înainte și după aplicarea ICA. Astfel, se face mai întâi maparea pe datele brute, apoi se face legătura pe baza id-ului comun și se găsește noua latență corespunzătoare din semnalul EEG.

În plus, pentru a evita situația în care un stimul începe într-o zonă lipsită de artefacte, însă intervalul epocii se intersectează totuși cu o zonă invalidă de semnal, am adăugat și o verficare suplimentară:

```
overlap = @(a,b,c,d) (a < d) && (b > c);
window_start = new_latency - pre_stimul;
window_end   = new_latency + post_stimul;
invalid = false;
for boundary = 1:length(boundaries)
    if overlap(win_start, win_end, boundaries(boundary), boundaries(boundary))
        invalid = true; break;
    end
end
```

5.1.3 Preprocesarea semnalului

Etapa de preprocesare este de asemenea o etapă obligatorie pentru analiza semnalelor EEG, iar pașii pe care i-am urmat au fost corespunzători cu literatura [5, 19, 3]. Astfel, am aplicat următoarele etape:

- Rereferențierea tuturor canalelor la media globală a acestora, pentru eliminarea zgomotului comun
- Filtru trece bandă Butterworth de ordinul 4 cu frecvențele de tăiere la 1Hz, respectiv 40Hz
- Filtru Notch suplimentar de 50Hz, factor de calitate $Q = 30$, pentru asigurarea eliminării zgomotelor provenite de la sistemul de achiziție
- Baseline correction a fost realizat prin scăderea din întreaga epocă a mediei calculate pe intervalul de 500 ms pre-stimul
- Rejecția epocilor în care maximul absolut al amplitudinii depășește $threshold = 75\ \mu$V

Pentru datele trecute deja prin ICA, s-a aplicat doar ultimul pas de rejecție, întrucât restul pașilor au fost incluși direct înainte de procesul de eliminare a zgomotului.

5.1.4 Extragerea caracteristicilor (Features extraction)

Întrucât metodele de clusterizare pe semnalul continuu nu sunt adesea foarte performante, dar și din indicațiile din literatură legat de analiza pe ERP [4, 6], am ales să analizez și varianta în care clusterizarea se face în baza unor anumite caracteristici extrase pe fiecare epocă.

Principalele caracteristici relevante pentru analiza ERP sunt din domeniul timpului, în funcție de legătura fiziologică relevantă pentru răspunsul cortical emoțional:

- N100 - calculată ca media amplitudinilor în intervalul $50 - 150$ ms, reflectând procesarea timpurie a stimulului, dar și alocarea atenției
- EPN (Early posterior negativity) - calculată ca media amplitudinilor în intervalul $120 - 300$ ms, fiind asociată cu diferențierea între nivelele de stimulare
- LPP (Late positive potential) fiind asociată cu diferențierea între nivelele de valență, cu atenția susținută voluntar și relevanța emoțională a stimului
  - early - calculată ca media amplitudinilor în intervalul $300 - 600$ ms
  - central - calculată ca media amplitudinilor în intervalul $600 - 950$ ms
  - late - calculată ca media amplitudinilor în intervalul $950 - 1200$ ms
  - total - calculată ca media amplitudinilor în intervalul $300 - 1200$ ms
  - slope - calculată ca diferența dintre lpp late și lpp early
  - ratio - calculat ca raportul dintre lpp early și lpp late

În plus, calculez și energia totală a semnalului, dar și valoarea Root mean square (RMS - calculată ca rădăcina pătrată a mediei pătratelor amplitudinilor semnalului, fiind o măsură a intensității acestuia), caracteristici prin care se descrie natura generală a ERP-ului.

Înainte de a se face analiza pentru clusterizare, am aplicat încă două procesări. În primul rând, din cauza variabilității datelor din cauza a factorilor externi cum ar fi nivelul de atenție sau oboseală, sau conectivitatea scalpului participanților, datele pot varia atât intra-subiect, cât și inter-subiecți. De aceea, am aplicat o normalizare Z-score pentru trăsăturile extrase, definită ca în formula (5.1). În al doilea rând, epocile pentru care energia și RMS deviază cu mai mult de 2.5 deviații standard sunt eliminate. Deși această metodă este asociată în mod uzual cu distribuții normale, condiție care nu este întotdeauna îndeplinită în cazul semnalelor ERP, a fost utilizată aici ca un criteriu practic pentru reducerea influenței zgomotului extrem.

$$z = \frac{x - \mu}{\sigma} \tag{5.1}$$

unde x reprezintă valoarea inițială a trăsăturii, μ media acesteia, iar σ deviația standard.

5.1.5 Clusterizare

Clusterizare bazată pe semnalele continue

Clusterizarea se bazează pe semnalul ERP mediu, normalizat prin Z-score. Am încercat două variante, atât prin metoda K-Means, utilizând distanța euclidiană, cât și metoda K-Medoids, bazată pe distanța DTW, pentru a facilita alinierea temporală a epocilor.

Clusterizarea bazată pe caracteristicile extrase - metoda K-means

Algoritmul se folosește de o matrice multidimensională cu trăsăturile pentru fiecare epocă și rulează în mai multe inițializări independente, utilizând parametrul `'Replicates', 20` din funcția kmeans (MATLAB Statistics and Machine Learning Toolbox) [10], pentru a reduce dependența de inițializarea aleatoare.

De asemenea, pentru validarea modului în care epocile sunt discriminate pe baza trăsăturilor extrase, am implementat un mod de cuantificare prin calculul distanței Euclidiene la nivel de intra-clasă (imaginile cu aceeași etichetă VAD) și la nivel de inter-clasă (calculând distanța față de toate celelalte etichete). Ideal, o separare bună a claselor implică atât o compactare ridicată a instanțelor din aceeași clasă (distanță intra-clasă mică), cât și o separare între clase diferite (distanță inter-clasă mare).

În plus, pentru a putea vizualiza spațial modul în care au fost împărțite epocile în clustere, am integrat PCA (Principale components analysis), care caută primele 3 componente principale, astfel încât să fie posibilă reprezentarea epocilor într-un spațiu $3D$ (cu etichete pentru fiecare subiect, reprezentate de forme geometrice). Fiecare cluster are, de asemenea, culoarea sa.

Clusterizarea DBSCAN (Density based spatial clustering of applications with noise

Am încercat și această metodă întrucât, spre deosebire de K-means, nu trebuie impus din start numărul de clustere. În plus, semnalul EEG având încă poate anumite ouliers, un avantaj al acestei metode este faptul că identifică automat aceste puncte și le etichetează ca pe un cluster separat. Algoritmul se bazează pe doi parametri principali: ϵ, care definește distanța maximă la care două puncte sunt considerate vecine și `MinPts`, care reprezintă numărul de puncte necesare pentru definirea unui cluster. Pentru a determina valoarea optimă a parametrului ϵ, am utilizat graficul k-distanțelor (k-distance graph). Valoarea este aleasă prin identificarea punctului de inflexiune din graficul reprezentării distanțelor de la fiecare punct la al k-lea (ales anterior) cel mai apropiat vecin, utilizat pentru identificarea regiunilor dense și a punctelor izolate.

Clusterizarea pe regiuni corticale

O altă abordare pe care am abordat-o a fost ca în loc de a face clusterizarea pe un singurul canal, aceasta să fie făcută pe anumite regiuni corticale: frontală, centrofrontală, centroparietală, occipitotemporală și occipitoparietală.

```
regions.frontal = ["Fp1","Fp2","AF3","AF4","F7","F8"];
regions.centrofrontal = ["F3","F4","FC1","FC2","FC3","FC4","FC5","FC6"];
regions.centroparietal = ["C1","C2","C3","C4","CP1","CP2","CP3","CP4","P1","P2","P3
    ","P4"];
regions.occipitotemporal = ["TP7","TP8","PO7","PO8","O1","O2"];
regions.occipitoparietal = ["P1","P2","P3","P4","PO7","PO8","O1","O2"];
```

În loc de a face o medie aritmetică a trăsăturilor pe canalele selectate pentru fiecare regiune, am făcut o medie ponderată în funcție de variația semnalelor în timp, astfel încât să nu domine un anumit canal, ci să fie într-adevăr o analiză pe regiunea selectată.

Această abordare a fost luată în considerare atât din punct de vedere fiziologic, diferența de valența fiind mai ușor de observat în regiunea centro-parietală, în zone posterior-centroparietale, fiind asociată și cu activitate occipito-temporală și parietală. În schimb, nivelul de stimulare apare diferențiat mai mult în zonele parietală și occipitală [6]. Prin acest tip de agregare regională, scade efectul zgomotului specific unui singur canal.

Clusterizarea cu categoriile colapsate (N -> L)

Un alt tip de paradigmă încercată a fost de a colapsa etichetele imaginilor, pentru a separa doar între nivel scăzut și ridicat, pe fiecare dintre cele trei direcții VAD. Astfel, o structură binară simplică problema pentru algoritmul de clusterizare, suprapunerea dintre clasele din spațiul de reprezentare devenind mai redusă, ceea ce poate facilita identificarea diferențelor dintre nivelurile de activare.

Astfel, am modificat vector de etichete încât pentru orice dimensiune catalogată drept neutră (N), aceasta să fie etichetată drept scăzută (L).

În rest, algoritmul este asemănător cu cel de clusterizare în funcție de trăsăturile extrase, însă cu etichetele originale.

5.1.6 Interfață creier-calculator (Brain-Computer Interface - BCI)

Conectarea și sincronizarea datelor în timp real

Pentru dezvoltarea BCI am utilizat `Lab Streaming Layer` (LSL) [7], care permite transmiterea și sincronizarea în timp real a datelor provenite din surse distincte, prin intermediul unor timestamp-uri comune.

Sistemul este alcătuit din calculatorul pe care se rulează analiza și din alt calculator, pe care este aplicația de colectare a semnalului EEG și a markerilor. Conectarea la cele două fluxuri de date este realizată prin căutarea pe rețea a acestora:

```
result_eeg = lsl_resolve_byprop(lib, 'type', 'EEG');
result_mrk = lsl_resolve_byprop(lib, 'name', 'IAPS_Markers');
```

După crearea conexiunii, extragerea continuă a datelor este făcută prin utilizarea unor obiecte de tip `inlet`, specifice LSL.

În timpul funcționării sistemului, se afișează în timp real atât graficul cu semnalul EEG, pe fiecare canal, cât și detalii în consolă în momentul apariției unui nou marker, cu timesptamp-ul asociat. Astfel, se poate face sincronizarea între stimuli și semnalul EEG. Această etapă este baza folosită pentru implementarea ulterioară a analizei în timp real.

Analiza în timp real

Pentru analiza în timp real, conexiunea se realizează între calculatorul pe care se face analiza și încă două calculatoare. Unul este cel pe care este înregistrat semnnalul EEG, la fel ca în secțiunea anterioară, transmițând continuu aceste date. Al doilea este calculatorul pe care rulează programul de afișare a stimulilor. Cel din urmă transmite astfel markerii stimulilor, cu tot cu numele imaginii afișate, care este asociată apoi cu eticheta corespunzătoare pe calculatorul cu analiza principală, prin intermediul unui dicționar deja construit.

Calculatorul principal primește doar timestamp-ul markerului, așa că pentru a construi epoca asociată stimulului, așteaptă să fie disponibile suficiente eșantioane pentru a extrage epoca reprezentată de 1500 ms post-stimul. Fiecare epocă extrasă este supusă acelorași etape de preprocesare utilizate și în analiza offline: rereferențiere, filtrare notch ($50Hz$) și trece bandă ($1 - 40Hz$), rejectare epoci cu amplitudini care depășesc un prag (75μV).

După preprocesarea epocii, se extrag caracteristicile, aceleași cu cele utilizate în analiza offline: energie, RMS, valorile medii asociate componentelor ERP, N100, EPN și LPP. Se actualizează continuu vectorii de caracteristici, memorați separați pentru fiecare canal.

Clusterizarea este realizată separat pentru fiecare canal, folosind K-means cu $k = 6$ clustere. La fiecare 10 epoci, se reactulizează clusterele, însă pentru a evita recalcularea completă, se utilizează ca punt de pornire centroizii calculați anterior (`warm-start`). În paralel, sunt calculate și salvate proiecțiile PCA și metricile de separabilitate dintre etichete, asemănător cu procesul desfășurat în analiza offline, permițând astfel urmărirea evoluției clusterizării pe parcursul analizei în timp real. Datele sunt salvate și pot fi vizualizate și ulterior, într-un obiect tip `.mat`.

5.2 Studiu 2

5.2.1 Segmentare

Segmenatarea semnalului se face pe trialuri, fără a mai diferenția epocile individuale pentru a fi analizate. Acestea se construiesc în funcție de primul și ultimul triger, reținuți în fișierul `.mat`. Pentru a capta și porțiunea post a ultimului stimul, la finalul trialului se adaugă încă 2 secunde.

Cu toate că frecvența de eșantionare nu este înregistrată, aceasta este calculată din vectorul de timp TS, ca $f_s = \frac{1}{\text{mean}(t_{i+1} - t_i)}$.

5.2.2 Preprocesare

Întrucât datele pe care am lucrat erau deja trecute prin procesele clasice de filtrare și preprocesare a datelor EEG, singura etapă aplicată în acest pas asupra datelor a fost ce de rejectare de epoci. Astfel, am aplicat o filtrare suplimentară pentru a nu include în analiză epocile afectate de artefacte majore, provenite de la mișcări oculare, musculare, factori experimentali etc. Aceasta se bazează pe deviația standard locală a puterii semnalului, a cărei puncte de extrem au fost standardizate și apoi eliminate dacă depășesc pragul de ± 3.0.

5.2.3 Matricea TSP (Putere spectrală topografică) și Reducerea dimensionalității prin PCA

Pentru a vizualiza semnalul continuu în domeniul frecvență, am calculat spectograma, bazată pe ferestre glisante calculate prin STFT (Short time fourier transform).

După izolarea epocilor curate, semnalul din domeniul timpului trebuie transpus într-o reprezentare capabilă să descrie topologia stărilor cerebrale. În acest scop, s-a calculat matricea de Putere Spectrală Topografică (TSP) prin calcularea unei spectrograme bazate pe ferestre glisante (Short-Time Fourier Transform - STFT). Fereastra selectată a fost de 2 secunde, cu un pas de 100ms. Din matricea rezultată s-au selectat benzile de frecvență de la 1.0Hz și 30.0Hz, rezultând un vector de 30 de caracteristici din domeniul frecvență.

Matricea TSP a fost normalizată prin Z-score, astfel încât rezultatele să apară drept abateri față de propria media a subiectului, matricile putând fi astfel comparate de la un subiect la altul.

De asemenea, prin intermediul PCA s-a redus dimensiunea matricei de frecevnțe, impunând a se reține 98% din varianța totală a semnalului. Această metodă este utilizată frecvent în literatură pentru a reduce numărul de caracteristici și a facilita antrenarea modelelor pe un spațiu de reprezentare mai compact [12].

Această alegere este frecvent utilizată în literatură pentru a reduce redundanța caracteristicilor și pentru a facilita antrenarea modelelor de clusterizare pe un spațiu de reprezentare mai compact.

5.2.4 Comparație algoritmi de clusterizare (K-Means vs. Ward vs. GMM)

Pentru identificarea și separarea macrostărilor activității cerebrale a șobolanilor, am ales să folosesc tehnici de învățare nesupervizată. Un punct important a fost astfel alegerea metodei de clusterizare. De aceea, am testat și comparat mai multe metode:

1. **Metoda K-Means**
2. **Metoda Ward**
3. **Modelele de Mixtură Gaussiană (GMM)**

Deoarece după identificarea clusterelor este necesară atribuirea etichetelor pe întreg semnalul continuu, am folosit și metoda K-NN (K nearest neighbors), folosind $K = 3$ și distanța euclidiană. Astfel, modelul este mai întâi antrenat pe datele folosite și pentru clusterizare, ca apoi să fie aplicat pe întregul semnal pentru a mapa fiecare punct către un anumit cluster, pe baza celor mai apropiați vecini.

5.2.5 Determinarea numărului de macrostări (k)

Un alt pas important în analiza este de a găsi o modalitate robustă pentru selecția numărului de clustere pentru care se va antrena modelul de clusterizare.

Am ales să rulez analiza de optimizare a lui k la nivel individual pentru fiecare subiect, și de a lua o decizie finală bazată pe agregarea acestor rezultate. Astfel, am iterat k în intervalul 2-10 și am folosit metoda Elbow [17], precum și metricile Silhouette [14], respectiv Calinski-Harabasz [16], metode standard pentru găsirea numărului optim de clustere. În cadrul metodei K-means, algoritmul este rulat de 10 ori pentru fiecare subiect, astfel încât inițializările aleatoare să nu aibă o influență crescută, rezultatele fiind apoi mediate.

În plus, am adăugat și o metodă de evaluare a numărului k bazată pe cum se schimbă separabilitatea datelor intra și inter clustere, în funcție de valoarea acestuia. Astfel, am calculat raportul dintre distanța euclidiană medie inter-cluster și cea intra-cluster:

$$raport(k) = \frac{\text{distanța inter-cluster medie}}{\text{distanța intra-cluster medie}} \tag{5.2}$$

5.2.6 Standardizarea macrostărilor

Deoarece etichetele asociate clusterelor sunt atribuite arbitar, fără o standardizare a acestora este imposibilă o comparație între subiecți sau o interpretare fziologică a acestora. De aceea, pentru fiecare cluster am calculat puterea spectrală medie, conform formulei (5.3) și le-am ordonat în funcție de valoarea obținută.

$$P_k = \frac{1}{|C_k| \cdot F} \sum_{i \in C_k} \sum_{j=1}^{F} |X_{i,j}| \tag{5.3}$$

- P_k reprezintă puterea spectrală medie a clusterului k;
- C_k este mulțimea ferestrelor temporale aparținând clusterului k, iar $|C_k|$ este numărul acestora;
- F reprezintă numărul total de trăsături spectrale per fereastră;
- $X_{i,j}$ este valoarea caracteristicii spectrale standardizate pentru fereastra i și componenta j

Astfel, există o legătură între cluster, care devine un prototip spectral pentru macrostările care aparțin acestuia, și nivelul de energie.

5.2.7 Analiza macrostărilor prin ocupanță

Rata de ocupanță este calculată ca fiind proporția în care o macrostare este activă într-o anumită perioadă de timp. Pentru a analiza dinamica unei anumite stări, se calculeaza ocupanța în două inetrvale - pre și post stimul - și se face diferența dintre ele. Astfel se definește:

$$DER = OcupantaPRE - OcupantaSTIM \tag{5.4}$$

Această diferență permite compararea dinamicii macrostării înainte și după stimul, și devine modalitatea de a compara macrostările între ele.

5.2.8 Identificare macrostare implicită

Diferența de ocupanță (DER) este folosit pentru a putea identifica macrostarea implicită, DEM (default macrostate). Această stare este definită ca fiind starea cu varianța maximă a ocupanței între ferestrele pre și post stimul:

$$DEM = \underset{\text{macrostare}}{\arg\max} \left(DER_{\text{macrostare}}\right) \tag{5.5}$$

5.2.9 Interpretare rezultate prin regresie liniară

Pentru a evalua în final rezultatele găsite și pentru a face diferențierea dintre grupurile experimentale, am folosit o analiză de regresie liniară între nivelul de ocupanță în perioada de dinainte de stimul și DER.

Datele au fost grupate pe intervale de ocupanță, din 20 în 20, pentru fiecare făcându-se media dintre valorile DER.

Datele sunt stratificate pe intervale de ocupanță pentru a reduce efectul variațiilor locale, iar pentru fiecare interval sunt calculate valorile medii ale DER.

Modelul de regresie are forma:

$$DER = \beta_1 \cdot OcupantaPRE + \beta_0 \tag{5.6}$$

Parametrii din formula (5.6) sunt estimați prin regresie liniară simplă, utilizând metoda celor mai mici pătrate.

Această analiză are ca scop diferențierea între grupurile experimentale, și de a exprima matematic modul în care nivelul de repaus în care se află subiectul înainte de stimulare determină nivelul de reactivitate.

6 Rezultate și Discuții

6.1 Studiul 1 - Analiza răspunsului cortical la stimuli vizuali afectiv

Vizualizare epoci semnal continuu

În figura 6.1 se pot vizualiza exemple ale epocilor înregistrate, în care este capturată forma unui potențial evocat (ERP), atât pre, cât și post stimul. Se poate observa scăderea inițială a amplitudinii semnalului imediat după apariția stimulului, urmată de creșterea către o amplitude maximă într-un interval scurt de timp. De asemenea, se pot observa și segmente apărute mai târziu de tip LPP. Acestea se pot observă atât prin medierea tuturor trialurilor unui participant, pe un anumit canal, cât și separat prin medierea răspunsului la un stimul individual.

Această vizualizare sugerează că etapa de preprocesare - de filtrare și de eliminare a zgomotului de fundal - a fost eficientă pentru a izola activitatea evocată de stimul, putând fi analizată ulterior. Astfel, semnalele ERP reprezintă punctul de pornire al analizei datelor EEG, fiind o primă viziualizare a răspunsului cortical la prezența unui stimul emoțional.

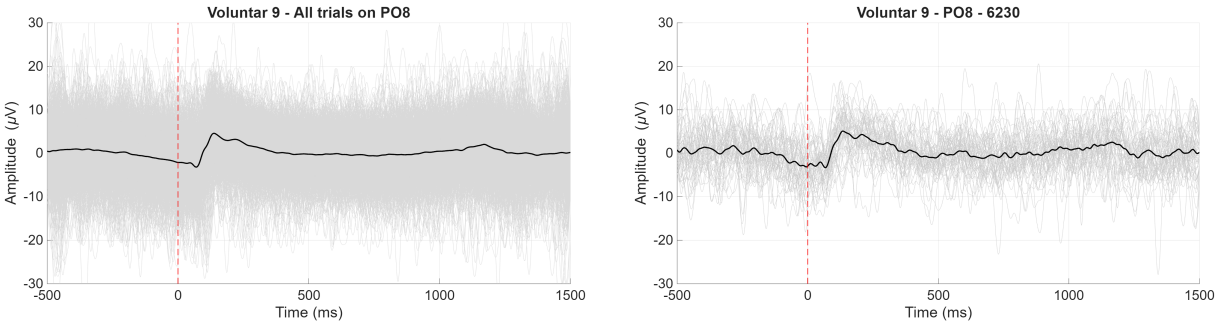


Figura 6.1: Exemple vizuale ale epocilor

Testare algoritmi de clusterizare pe semnalul continuu

O primă analiză a fost desfășurată direct asupra epocilor din semnalul continuu, antrenând un model de clusterizare K-means. Din Figura 6.2 se observă că antrenarea pe aceste date a dus la un model care împarte datele în clustere într-un mod dezechilibrat, unele având majoritatea epocilor, în timp ce restul clusterelor rămăn slab populate.

Acest rezultat indică faptul că structura semnalului luat ca un întreg este dominată de variații globale, fiind greu de delimitat de către algoritm diferențele mai subtile, prin care ar fi fost identificate caracteristicile specifice pentru tipurile diferite de stimulări emoționale.

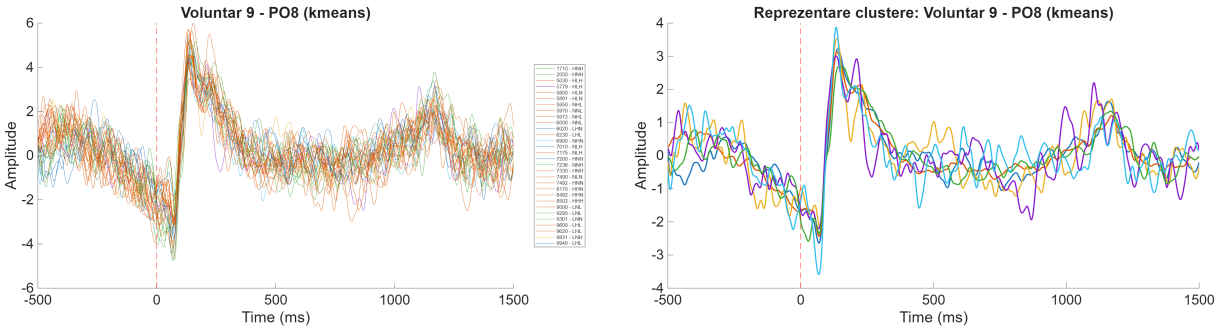


Figura 6.2: Clusterizarea pe semnal continuu utilizând algoritmul K-Means.

Distribuția dezechilibrată a epocilor în clusterele identificate (valorile numerice reprezintă codurile asociate imaginilor din setul de stimuli):

- **Cluster 1:** 6020 - LHN, 7010 - NLH, 7200 - HNH, 9940 - LHL
- **Cluster 2:** 5030 - HLH, 5800 - HLN, 5891 - HLN, 5950 - NHL, 5970 - NNL, 5972 - NHL, 6000 - NNL, 6230 - LHL, 7175 - NLH, 7330 - HNH, 7490 - NLN, 7492 - HNN, 8170 - HHN, 8492 - HHN, 8502 - HHH, 9000 - LNL, 9600 - LHL, 9620 - LHL
- **Cluster 3:** 9831 - LNH
- **Cluster 4:** 5779 - HLH
- **Cluster 5:** 1710 - HNH, 2050 - HNH, 7236 - NNH, 9295 - LNL, 9301 - LNN
- **Cluster 6:** 6900 - NHN

Am luat în considerare și posibilitatea apariției unor decalaje temporale în ERP-urile de la o epocă la alta, motiv pentru care am încercat și metoda K-medois, bazată pe distanța Dynamic time warping (DTW). Teoretic, acesta duce la alinierea segmentelor de timp importante din ERP-uri, ducând la un calcul al similarității între epoci mai potrivit. Astfel, variațiile în latență nu ar mai afecta atât de mult modelul de clusterizare și s-ar putea evidenția anumite tipare existente, însă nesincronizate la nivel temporal.

Însă noul model a accentuat dezechilibrul dintre clustere, chiar și la scăderea numărului de clustere considerat inițial (de la 6 la 4). În acest caz, există un singur cluster dominant, iar restul clusterelor sunt populate cu o epocă din obligativitatea impusă de numărul de clustere cerut (Figura 6.3).

Din cauza acestor rezultate, s-a renunțat la acest algoritm pentru analizele următoare.

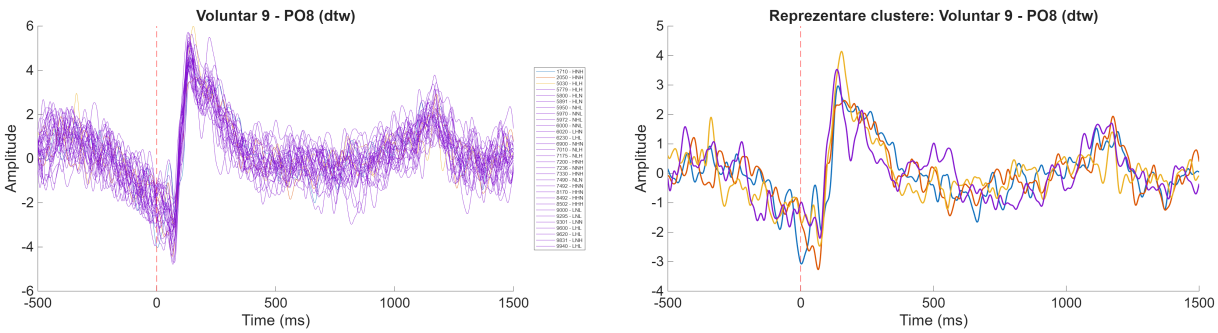


Figura 6.3: Clusterizarea pe semnal continuu utilizând algoritmul DTW.

Distribuția epocilor pentru DTW, observându-se un monopol pe clusterul 4:

- **Cluster 1:** 1710 - HNH
- **Cluster 2:** 2050 - HNH
- **Cluster 3:** 5030 - HLH
- **Cluster 4:** 5779 - HLH, 5800 - HLN, 5891 - HLN, 5950 - NHL, 5970 - NNL, 5972 - NHL, 6000 - NNL, 6020 - LHN, 6230 - LHL, 6900 - NHN, 7010 - NLH, 7175 - NLH, 7200 - HNH, 7236 - NNH, 7330 - HNH, 7490 - NLN, 7492 - HNN, 8170 - HHN, 8492 - HHN, 8502 - HHH, 9000 - LNL, 9295 - LNL, 9301 - LNN, 9600 - LHL, 9620 - LHL, 9831 - LNH, 9940 - LHL

Același tip de analiză ca în încercarea inițială, de clusterizare direct pe semnalul continuu, a fost aplicat și pe semnalul suspus la ICA. Cu toate că a existat o îmbunătățire în ceea ce privește distribuția mai uniformă a punctelor în clusterele, rezultatele au fost în continuare suboptime (Figura 6.4).

Astfel, supunerea semnalului la o astfel de preprocesare conduce la o creștere a coerenței interne între epoci, deci este un punct de considerat în analizele desfășurate mai târziu. Însă în continuare metoda de clusterizare pe întregul semnal nu dă performațele dorite.

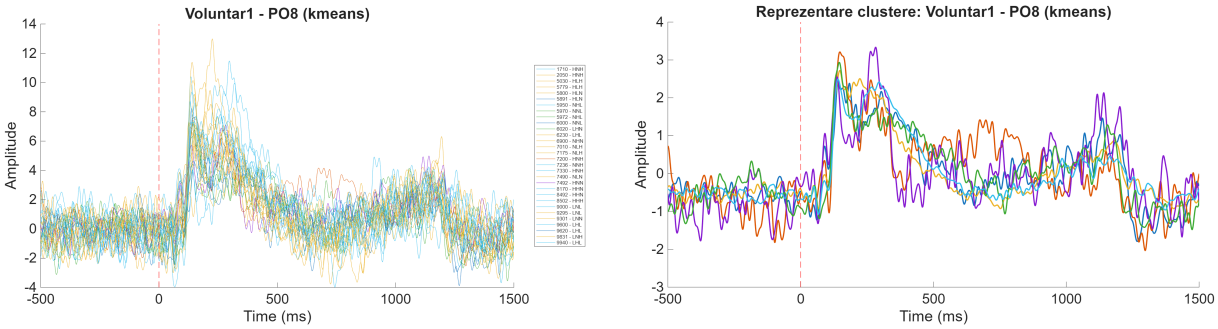


Figura 6.4: Clusterizarea pe semnal continuu curățat cu ICA utilizând metoda K-Means.

Distribuția pe clustere a epocilor suspuse la ICA:

- **Cluster 1:** 1710 - HNH, 5891 - HLN, 5970 - NNL, 6230 - LHL, 7200 - HNH, 7236 - NNH, 8170 - HHN, 8502 - HHH
- **Cluster 2:** 7010 - NLH, 7330 - HNH
- **Cluster 3:** 5950 - NHL, 6020 - LHN, 6900 - NHN, 9000 - LNL, 9600 - LHL
- **Cluster 4:** 2050 - HNH, 5972 - NHL, 6000 - NNL, 7492 - HNN, 8492 - HHN, 9295 - LNL
- **Cluster 5:** 9301 - LNN, 9831 - LNH, 9940 - LHL
- **Cluster 6:** 5030 - HLH, 5779 - HLH, 5800 - HLN, 7175 - NLH, 7490 - NLN, 9620 - LHL

Întrucât a fost observată în mai multe situații de analiză, am considerat că paradigma bazată pe epoca întreagă este limitată și am abandonat-o. În schimb, am continuat analiza cu modele bazate pe trăsături extrase din ERP.

6.1.1 Clusterizarea bazată pe caracteristici extrase

Înainte de antrenarea efectivă a modelului de clusterizare pe trăsăturile extrase, am rulat și o analiză care a constat în calculul distanțelor intra și inter clasă pentru fiecare trăsătură, la nivelul fiecărui subiect. Scopul a fost de a verifica ce caracteristici sunt cele mai potrivite pentru a fi utilizate, astfel încât să ducă la o diferențiere mai bună a tipurilor de stimuli, în funcție de etichetele acestora. În Figura 6.5 se poate observa rezultatul unei astfel de analize pentru un anumit subiect, pentru canalul ”PO8”. În final, am ales să desfășor analiza considerând următoarele trăsături:

Analiza a constat în calculul distanțelor intra-clasă și inter-clasă pentru fiecare trăsătură, la nivelul fiecărui subiect.

```
feat_vector = [
    f.energy, ...
    f.rms, ...
    f.mean_n100, ...
    f.mean_epn, ...
    f.mean_lpp_early, ...
    f.mean_lpp_late, ...
];
```

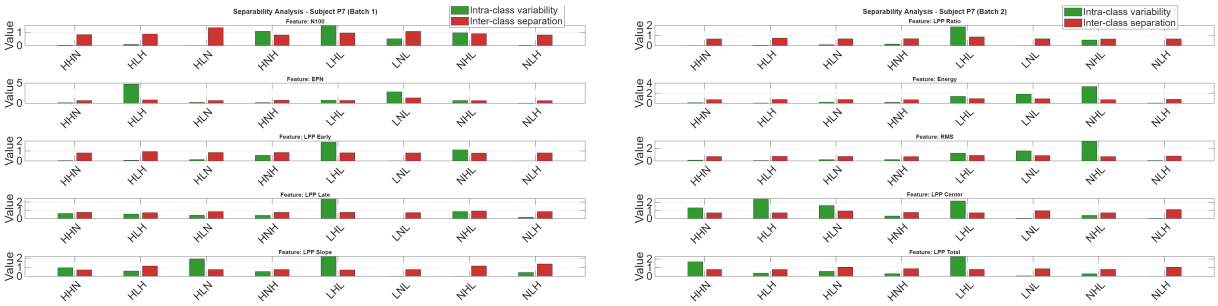


Figura 6.5: Separabilitatea caracteristicilor brute.

Astfel, după trecerea la antrenarea modelului pe vectorii cu trăsăturile extrase, se observă o îmbunătățire legată de cât de echilibrate sunt clusterele găsite. Analizând Figura 6.6, se observă că separabilitatea inter-clasă are majoritar o valoare mai mare decât cea intra-clasă, însă cele două valori sunt totuși foarte apropiate. De asemenea, observând proiecția PCA din Figura 6.7, se vede faptul că există o suprapunere între clustere. Astfel, cu toate că această nouă paradigmă duce la un echilibru la nivelul numărului de epoci per cluster, restul rezultatelor indică existența unor surse de variabilitate care nu sunt capturate, sau de prezența unui zgomot care limitează performanța acestei abordări.

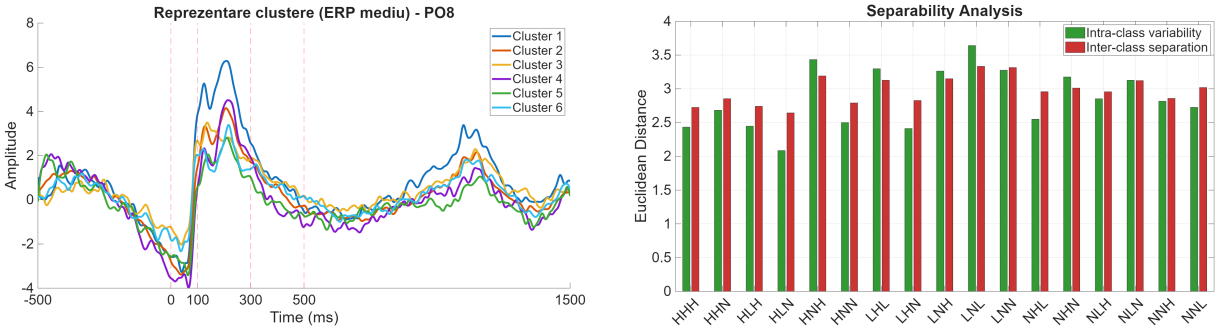


Figura 6.6: Clusterizarea bazată exclusiv pe caracteristici extrase.

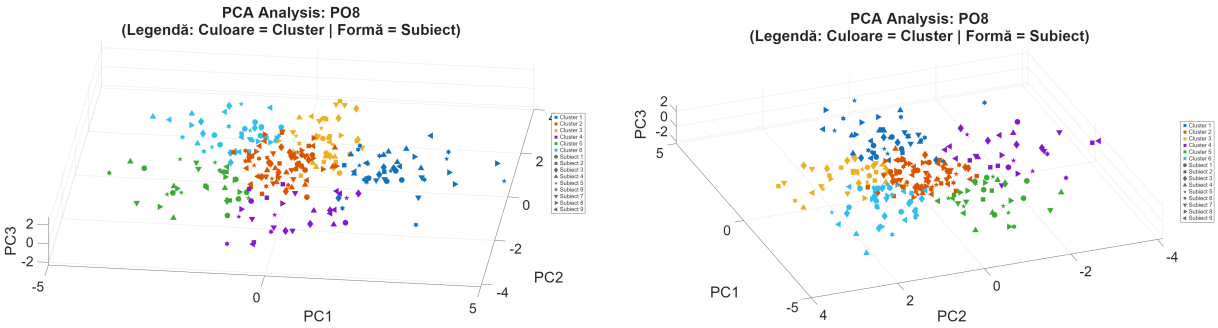


Figura 6.7: Proiecția PCA a clusterizării bazate pe caracteristici brute (suprapunere vizibilă a stărilor).

Am reluat aceeași analiză și pentru datele pe care a fost aplicat ICA. Am continuat cu același set de trăsături, pentru a putea compara rezultatele. Astfel, în Figura 6.8, se poate observa că discrepanța dintre valorile de separabilitate este mai mare, și de asemenea, valorile inter-clasă sunt mai mari. Acest lucru indică o creștere a discriminabilității dintre grupuri pentru analiza pe datele supuse la ICA, față de cele brute.

De asemenea, prin analiza Figurii 6.10, se poate observa o diferențiere mai pronunțată a clusterelor, cu toate că unele dintre ele se suprapun în continuare. Acest rezultat indică faptul că aplicarea ICA înainte de analiză contribuie la evidențierea unor surse de variație între epoci.

Cu toate că rezultatele nu sunt încă la nivelul de performanță dorit, acest pas indică faptul că supunerea la ICA aduce un plus analizei.

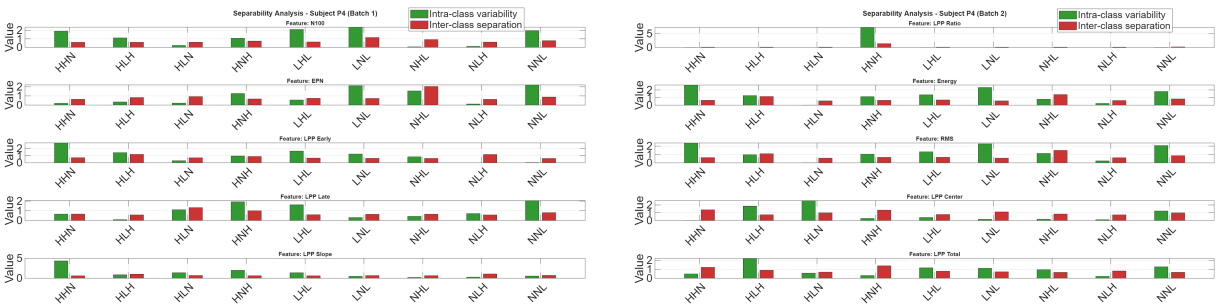


Figura 6.8: Separabilitatea caracteristicilor după ICA

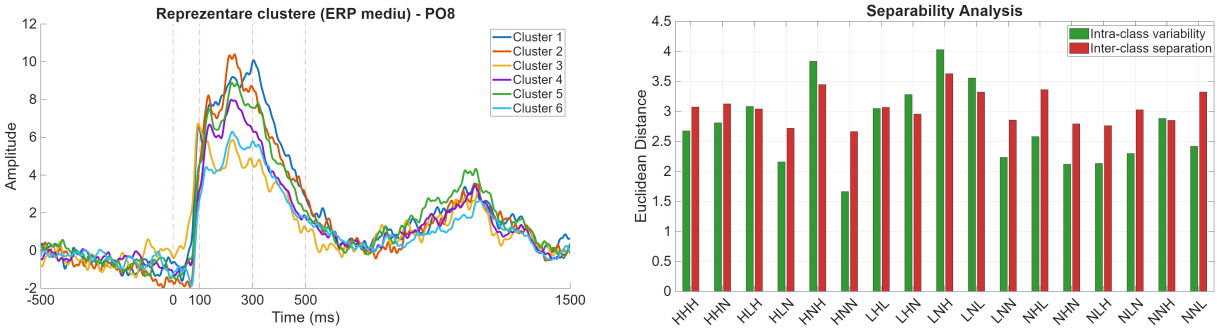


Figura 6.9: Clusterizare pe baza caracteristicilor, post-ICA

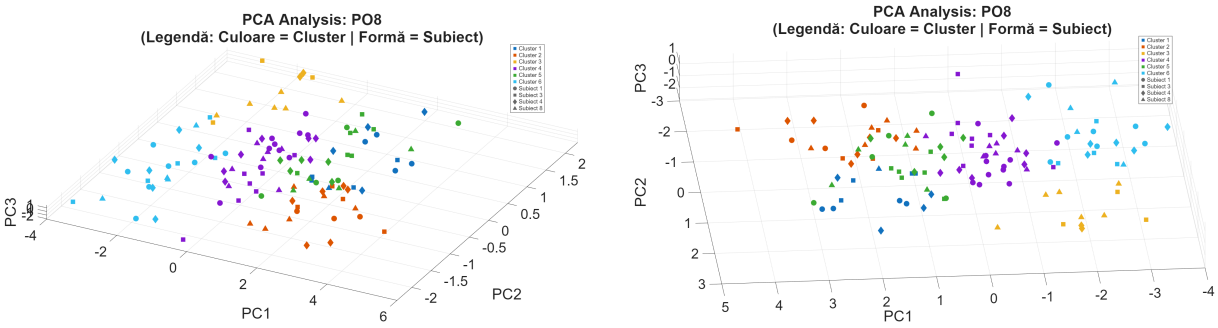


Figura 6.10: Proiecția PCA post-ICA

Algoritmul DBSCAN

O altă abordare încercată a fost antrenarea unui model pe baza algoritmului DBSCAN, care are principalul avantaj de a nu impune la început numărul de clustere. În schimb, problema se pune la alegerea parametrului `epsilon`. În acest sens, am utilizat graficul distanțelor k-NN (Figura 6.11) pentru a găsi valoarea optimă a acestui parametru, prin identificarea punctului de inflexiune a curbei.

Cu toate că algoritmul a reușit să izoleze anumite puncte, considerându-le zgomot sau ca fiind atipice (punctele negre din Figura 6.12), acest număr este ridicat considerând numărul total de puncte. În plus, modul în care au fost împărțite epocile rămase este dezechilibrat.

Astfel, cu toate că această abordare s-a dovedit robustă la zgomot, eficiența în contextul analizei neurofiziologice este scăzută întrucât este important ca majoritatea epocilor să fie încadrate într-un cluster, dovedindu-se mai puțin potrivită față de abordările anterioare.

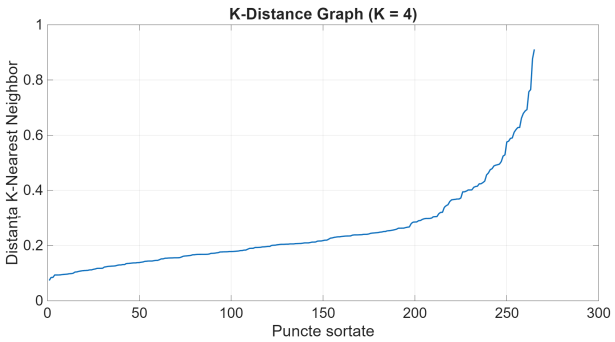


Figura 6.11: Determinarea parametrului epsilon pentru DBSCAN

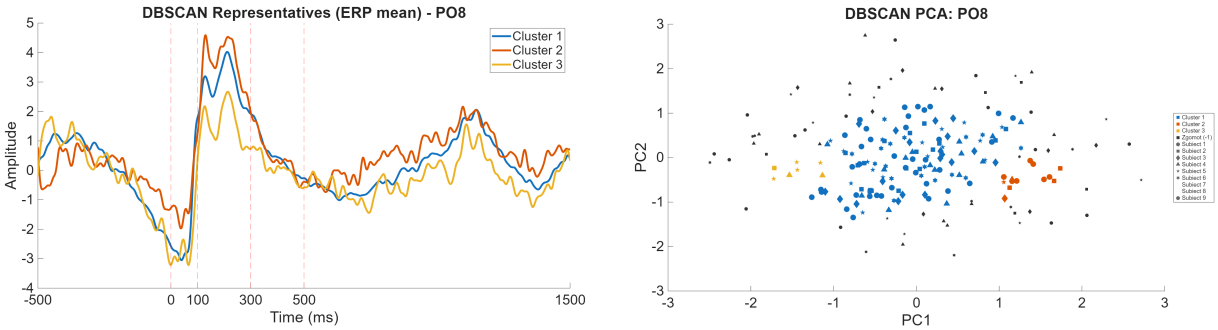


Figura 6.12: Clusterizarea DBSCAN

6.1.2 Variante de optimizare a clusterizării

O altă abordare a constant în analiza la nivelul unor regiuni corticale specifice, în loc de analiza făcută pe un singur canal.

Din rezultatele din Figura 6.13 se observă că valorile separabilității inter-clase cresc, ceea ce confirmă faptul că prin această abordare se evidențiază mai bine variabilitatea între tipurile de stimuli. Însă prin analiza Figurii 6.14 se observă o suprapunere mult mai mare a clusterelor, provenită din natura regiunii, care, din punct de vedere neurofiziologic, se ocupă mai puțin cu procesarea vizuală și emoțională față de alte regiuni.

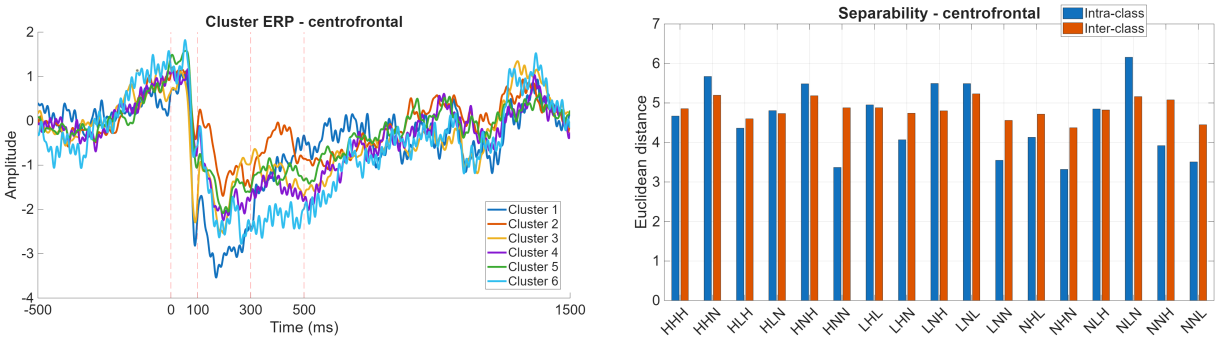


Figura 6.13: Clusterizăre regiune centro-frontală

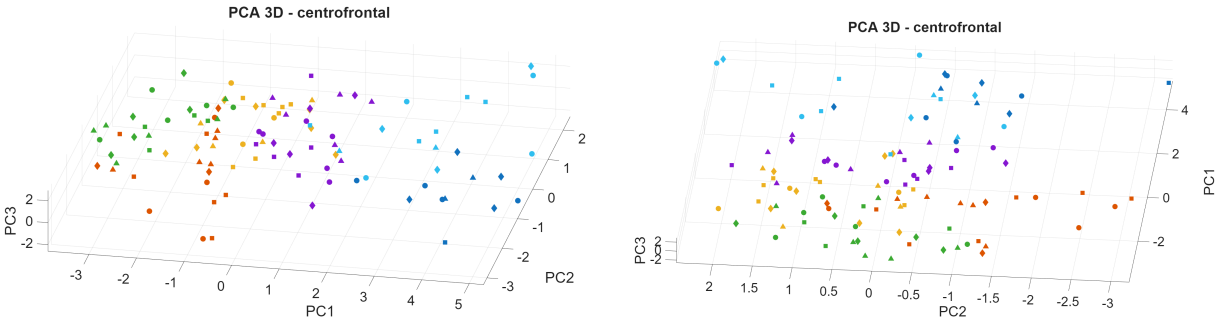


Figura 6.14: Proiecție PCA regiune centro-frontală

În Figura 6.15, pentru analiza caracteristicile extrase din regiunea occipio-parietală, se observă aceeași creștere a valorilor separabilității inter-clase, la fel ca anterior. În schimb, în

Figura 6.16, unde datele sunt proiectate în spațiul componentelor principale, nu mai există aceeași tendință la fel de puternică de suprapunere a claselor. Astfel, această variantă oferă o separare mai bună în clase a etichetelor imaginilor.

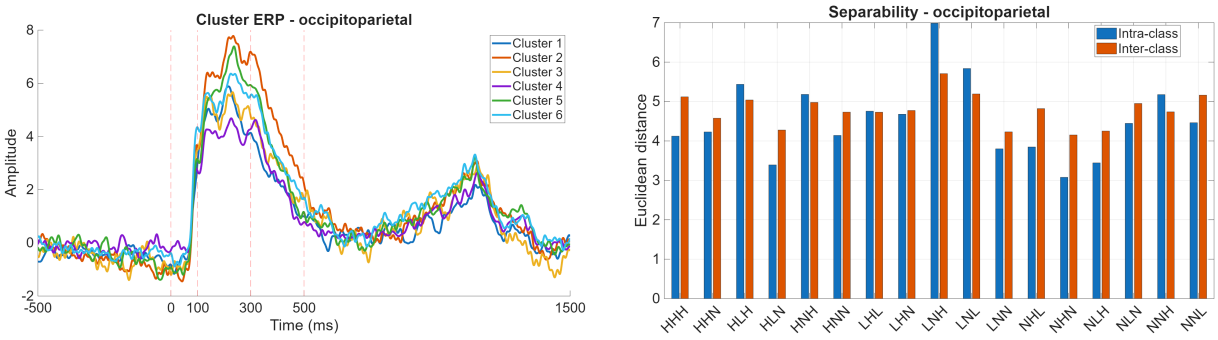


Figura 6.15: Clusterizăre regiune occipito-parietală.

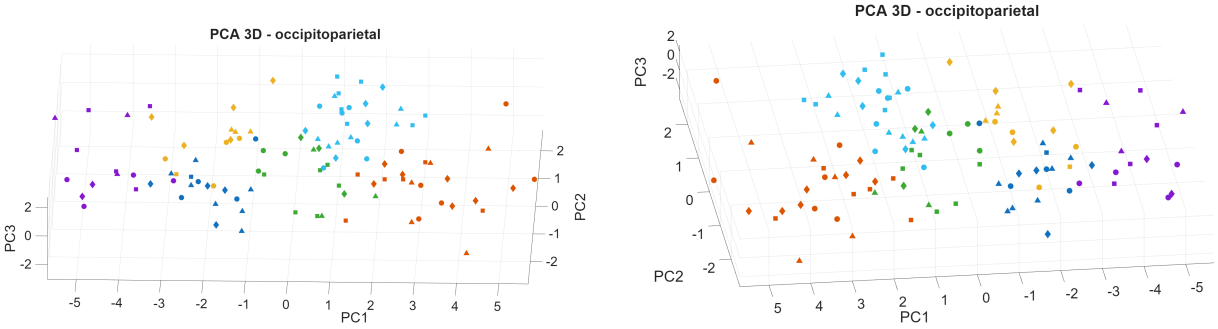


Figura 6.16: Proiecție PCA regiune occipito-parietală

O ultimă abordare încercată a constat în unificarea categoriilor neutru (N) și scăzut (L) în cadrul etichetării stimulilor. Astfel, am încercat eliminarea unei posibile ambiguități cauzată de asemănarea intensității stimulilor din cele două categorii.

Cu toate acestea, în Figura 6.17 se observă că valorile separabilității inter-clasă scad și sunt apropiate de cele intra-clasă. De asemenea, în Figura 6.18, unde datele sunt proiectate în spațiul componentelor principale, se poate observa suprapunerea destul de mare între anumite clase. Astfel, această abordare s-a dovedit a fi suboptimă.

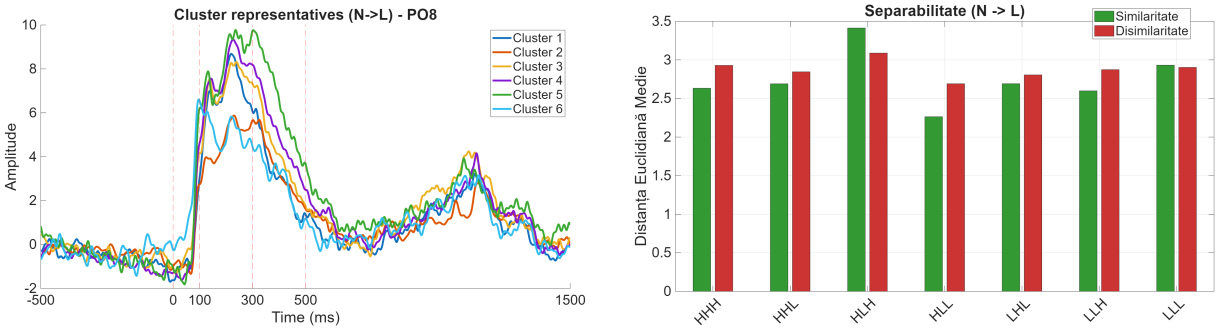


Figura 6.17: Performanța modelului în clasificarea binară (stările Neutre colapsate în Low).

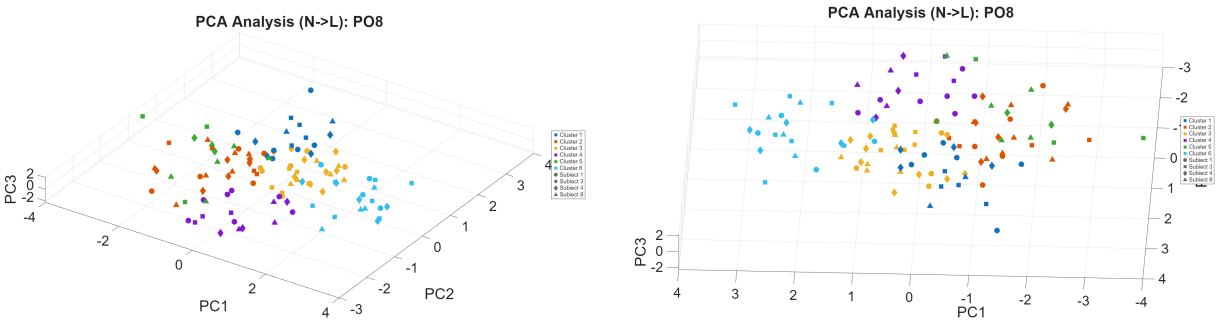


Figura 6.18: Performanța modelului în clasificarea binară (stările Neutre colapsate în Low).

Din cauza suprapunerii claselor pentru $k = 6$, număr impus de clustere, am testat și varianta cu $k = 4$, ceea ce a dus la o suprapunere cu mult mai redusă a claselor.

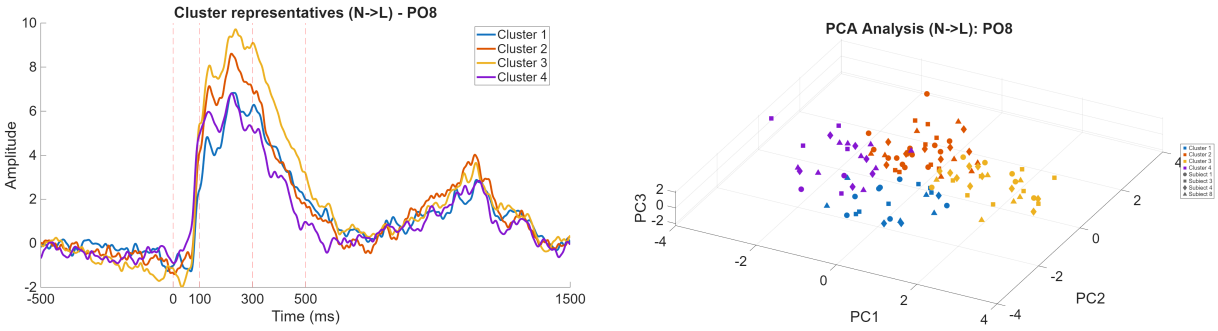


Figura 6.19: Performanța modelului în clasificarea binară (stările Neutre colapsate în Low).

6.1.3 BCI

Sistemul a fost testat pe 17 trial-uri, pe un singur subiect, în momentul testării scopul principal fiind de validare a funcționării lanțului de analiză în timp real.

Conectarea și sincronizarea datelor în timp real

Dezvoltarea sistemului BCI a permis vizualizarea semnalului EEG înregistrat și monitorizarea markerilor în timp real.

În figurile 6.20 și 6.21 se pot observa câteva capturi de ecran din timpul achiziționării și vizualizării semnalului în timp real, pe diferite canale. Se pot observa fluctuații de amplitudine ale activității corticale, cât și prezența unor artefacte fiziologice.



Figura 6.20: Capturi de ecran din monitorizarea în timp real a semnalului EEG pentru diferite canale

În Figura 6.21 se poate observa un aspect suplimentar, pentru canalul 32. Acesta are o amplitudine constantă nulă, comportamentul fiind unul așteptat întrucât electrodul asociat canalului este electrodul de referință a sistemului. Astfel, se confirmă că semnalul este achiziționat corespunzător.

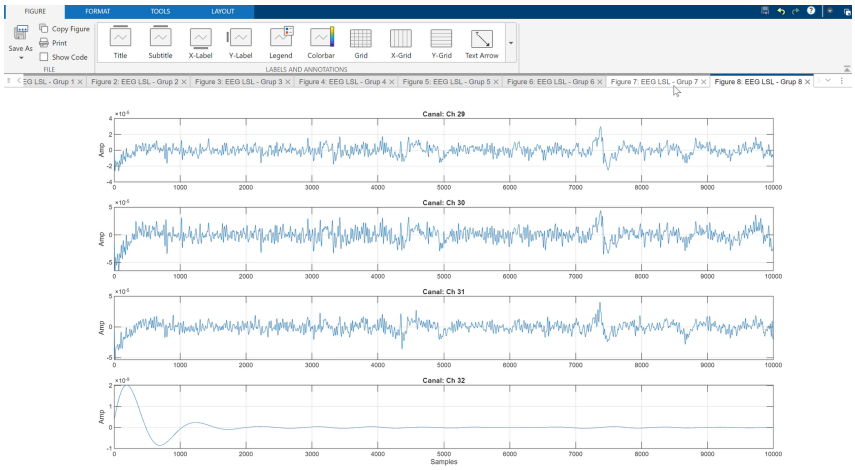


Figura 6.21: Capturi de ecran din monitorizarea în timp real a semnalului EEG pentru diferite canalele 29-32

În paralel, au fost afișați în timp real în consolă markerii primiți prin al doilea flux de date LSL, împreună cu timestamp-urile asociate.

Analiza în timp real

Figura 6.22 ilustrează evoluția proiecțiilor PCA din timpul expereimentului, pe măsură ce se acumulează epoci noi și sunt actualizate clusterele. Se observă că în primele etape, distribuția datelor este mai dispersată, însă pe parcurs datele încep să aibă o organizare mai clară. Figura 6.23 reprezintă ultimele etape din analiza în timp real, distribuția datelor devenind mult mai densă. Se observă pe parcurs că există o continuitate între etape, datorită startegiei utilizate de tip *warm-start*.

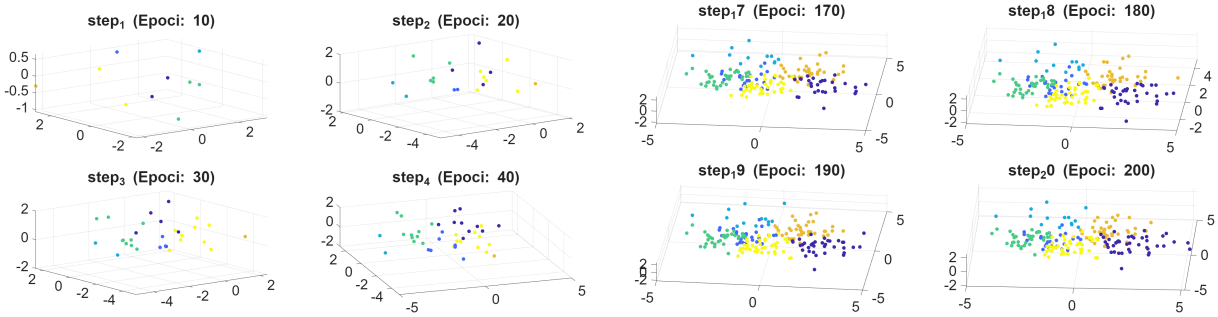


Figura 6.22: Evoluție clustere

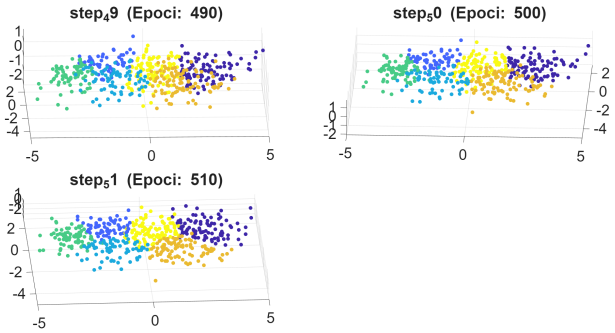


Figura 6.23: Clustere finale

Evoluția datelor a mai fost monitorizată și prin calcularea metricilor de separabilitate pentru fiecare etapă, ilustrată în Figura 6.24. În etapele inițiale, anumite etichete nu sunt încă suficient reprezentate, ceea ce duce la lipsa unora dintre ele din figură. Rezultatul final este ilustrat în Figura 6.25 și se observă că valorile calculate pentru distanțele dintre clase devin stabile, indicând păstrarea unei structuri a datelor, după actualizările succesive care au fost făcute asupra clusterelor.

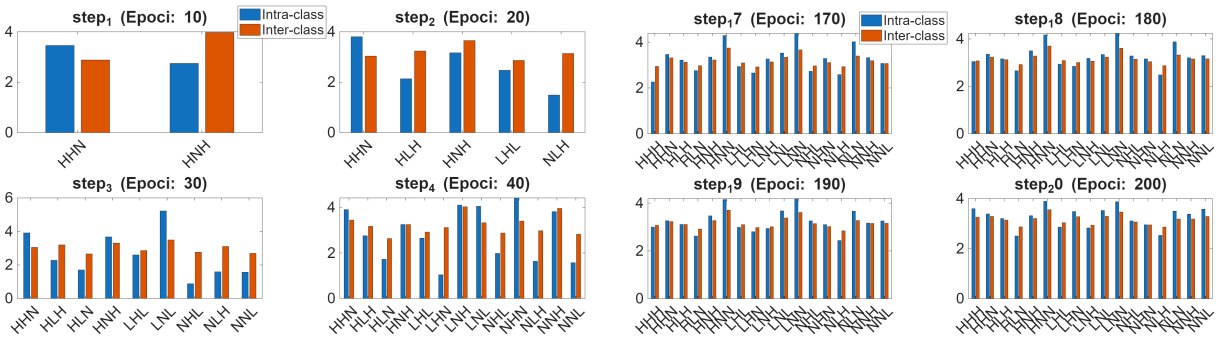


Figura 6.24: Evoluție clustere - metrica separabilitate

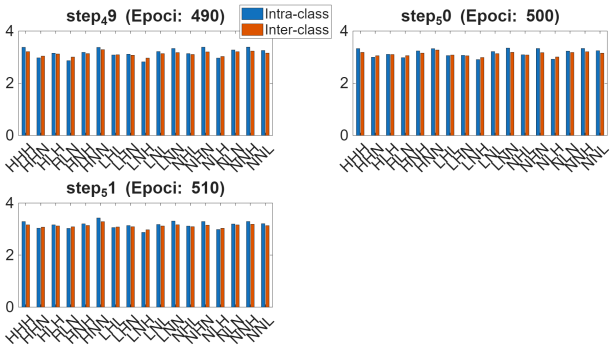


Figura 6.25: Clustere finale - metrica separabilitate

6.1.4 Discuții finale

În ansamblu, rezultatele indică faptul că cerința de diferențiere a stărilor emoționale pe baza răspunsurilor corticale înregistrate prin EEG depinde mult de modul de reprezentare a datelor. Modelul antrenat direct pe semnalul continuu nu a oferit o structură de clusterizare echilibrată, variabilitatea răspunsurilor neputând fi explicată doar prin diferențe temporale analizate pe întreg semnalul. În schimb, trecerea la analiza trăsăturilor extrse a condus la o îmbunătățire privind separabilitatea etichetelor. În plus, aplicarea ICA înainte de antrenarea modelului contribuie suplimentar la clarificrea structurii datelor datorită reducerii zgomotului și a artefactelor. În plus, reducerea analizei pe regiuni corticale față de pe canale individuale a adus un plus pentru performanța separabilității.

6.2 Studiul 2 - Analiza dinamicii activității cerebrale în condiții de alterare farmacologică a stării de conștiență

6.2.1 Reprezentarea spațio-frecvențială și analiza globală

Figura 6.26 prezintă reprezentarea datelor sub forma matricelor TSP, normalizate sub formă de Z-score, reprezentând o vizualizare a puterii spectrale în funcție de timp. Analizând diferențele dintre exemplele pentru grupurile ISO și CHL, se poate observa că în grupul ISO puterea este mai scăzută în primele secunde, ca pe parcurs să devină mai puternică. În schimb, în grupul CHL, puterea este destul de uniformă pe întregul interval de timp.

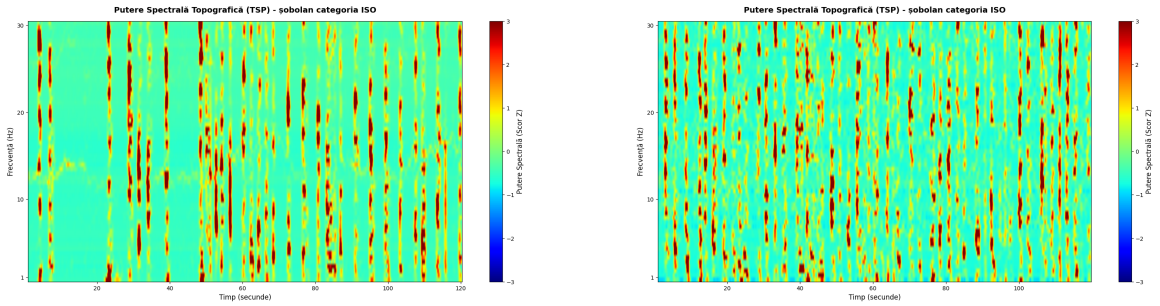


Figura 6.26: Comparație TSP: ISO vs. CHL

6.2.2 Determinare număr optim de clustere k

Un punct important în desfășurarea analizei a fost determinarea numărului optim de clustere. În acest sens, în Figurile 6.27 și 6.28 sunt ilustrate rezultatele acestei analize, desfășurată pe grupul ISO, respectiv CHL. Astfel, scorul Silhouette, indicele Calinski și raportul de separabilitate inter/intra converg consistent către soluția optimă de $k = 2$, pentru toate cele trei valoarea fiind maximă pentru acest număr de clustere. Însă această abordare, deși are cele mai bune rezultate din punct de vedere metric, este limitativă din punctul de vedere al unei interpretări neurofiziologice. Dinamica cerebrală nu poate fi simplificată la doar două macrostări, fiind insuficiente pentru a descrie complexitatea variațiilor corticale.

De aceea, în contextul analizei desfășurate, am ales un compromis. În acest sens, analiza metodei Elbow, sugerează că un numărul de clustere $k = 6$ reprezintă un punct de saturație pentru câștigul informațional, după aceste valori câștigul aplatizându-se odată cu creșterea numărului de stări. În același timp, și în cadrul metricilor anterioare se evidențiază o tendință de stabilizare a valorilor în jurul numărului de stări $k = 6$. În plus, variațiile pentru distanțele euclidiene medii nu sunt foarte mari, ceea ce validează alegerea acestui număr de clustere.

Astfel, deși soluția optimă din punct de vedere metric rămâne $k = 2$, în contextul analizei unor date EEG, alegerea lui $k = 6$ oferă un compromis echilibrat între validitatea numerică și utilitatea pentru analiza dinamicii corticale.

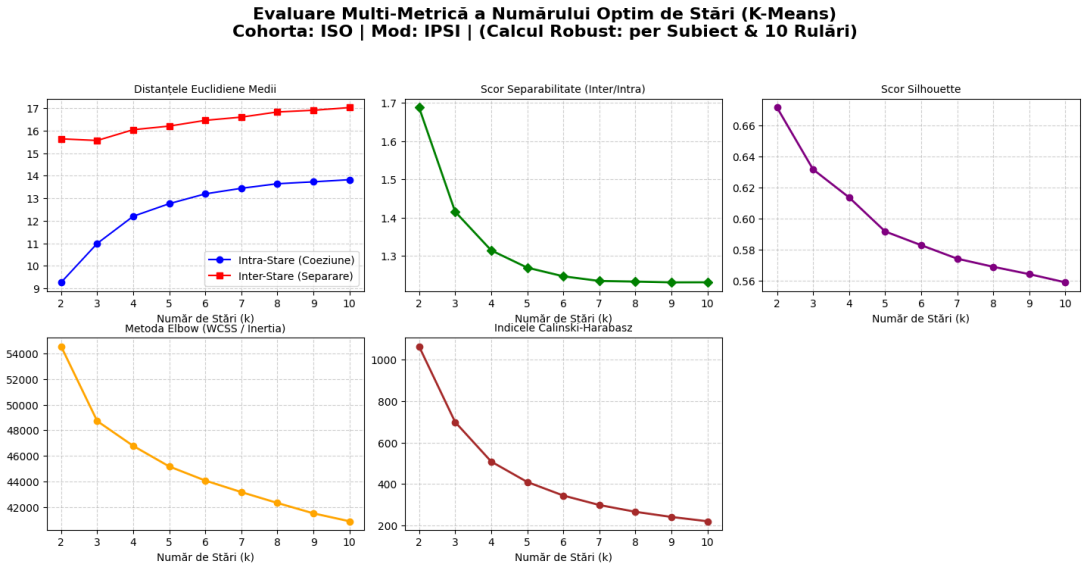


Figura 6.27: Reactivitatea stării DEM pentru înregistrările din grupul Control (Normoxie).

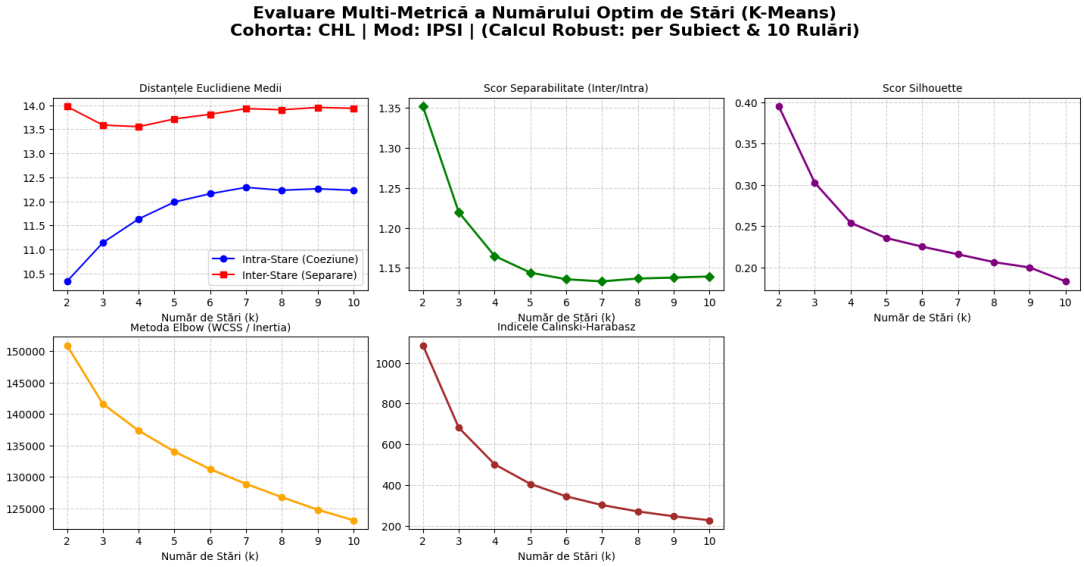


Figura 6.28: Reactivitatea stării DEM pentru înregistrările din grupul Control (Normoxie).

6.2.3 Comparație Algoritmi: K-Means vs. Ward

În Figurile 6.29 - 6.34 sunt prezentate profilurile celor $k = 6$ macrostări identificate și reactivitatea globală a fiecăreia, cu rezultatul pentru starea care a fost identificată drept DEM, pentru fiecare dintre cele trei grupuri, pentru metodele K-means și Ward.

Se observă că pentru toate grupurile experimentale, starea identificată drept DEM corespunde macrostării 1, indiferent de metoda de clusterizare utilizată. Datorită ordonării crescătoare a macrostărilor în funcție de energia medie, acest rezultat indică faptul că starea DEM este asociată cu cel mai redus nivel de energie. De asemenea, în ceea ce privește reactivitatea, valorile estimate sunt comparabile între metode (diferențe absolute: 0.8% ISO, 1.1% CHL, 0.6% control), fără a se observa un tipar consistent care să sugereze superioritatea uneia dintre metode în generarea unei reactivități mai ridicate.

De asemenea, se observă și o consistența în ceea ce privește macrostarea cu cea mai mare reactivitate negativă (macrostarea 2), evidențiindu-se coerența dintre rezultatele obținute prin cele două metode de clusterizare.

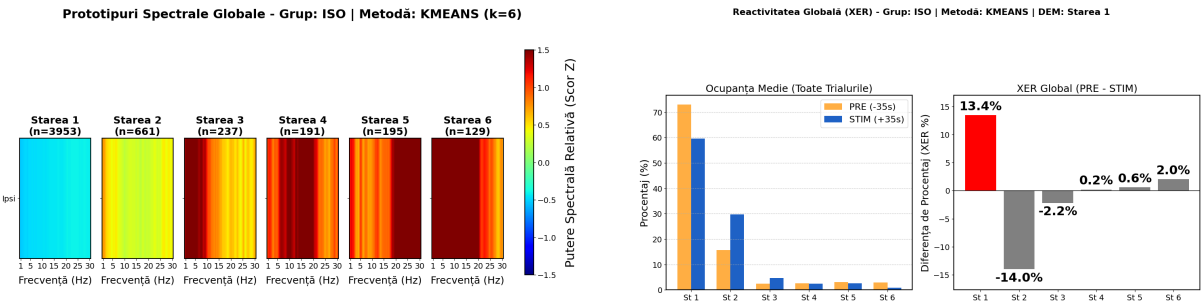


Figura 6.29: Prototipurile TSP, Ocupanța și Reactivitatea macrostărilor identificate: Grupul ISO, Metoda K-Means

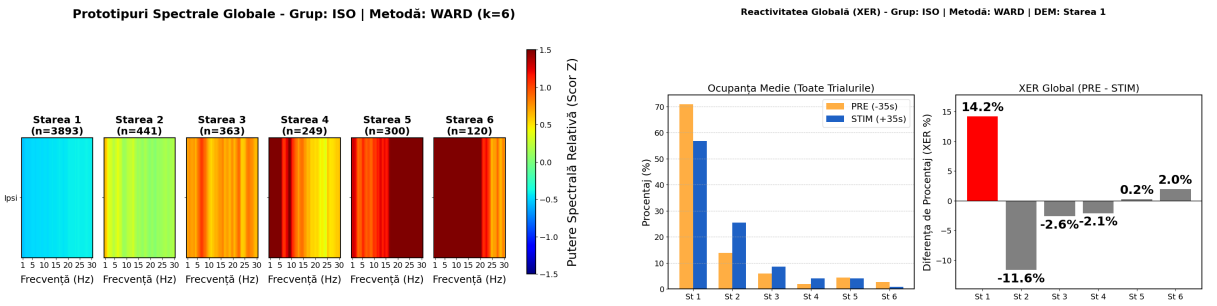


Figura 6.30: Prototipurile TSP, Ocupanța și Reactivitatea macrostărilor identificate: Grupul ISO, Metoda Ward

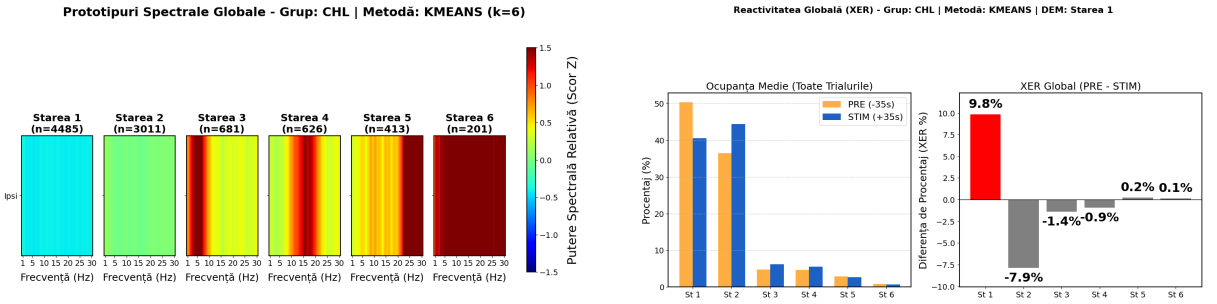


Figura 6.31: Prototipurile TSP, Ocupanța și Reactivitatea macrostărilor identificate: Grupul CHL, Metoda K-Means

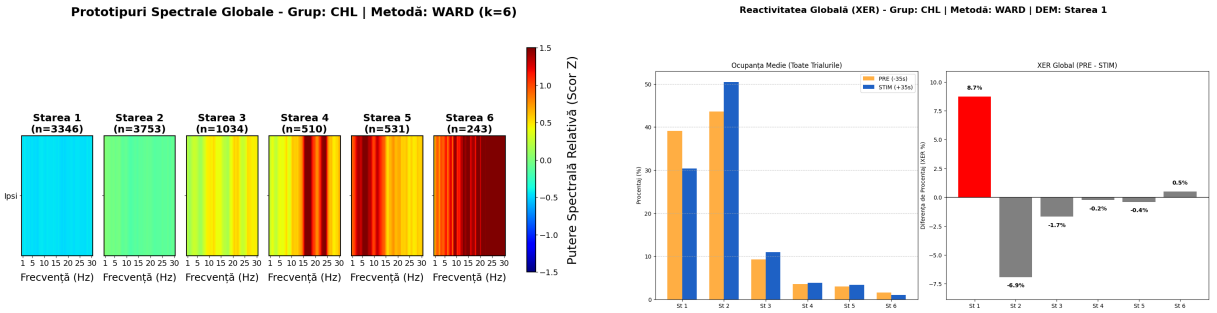


Figura 6.32: Prototipurile TSP, Ocupanța și Reactivitatea macrostărilor identificate: Grupul CHL, Metoda Ward

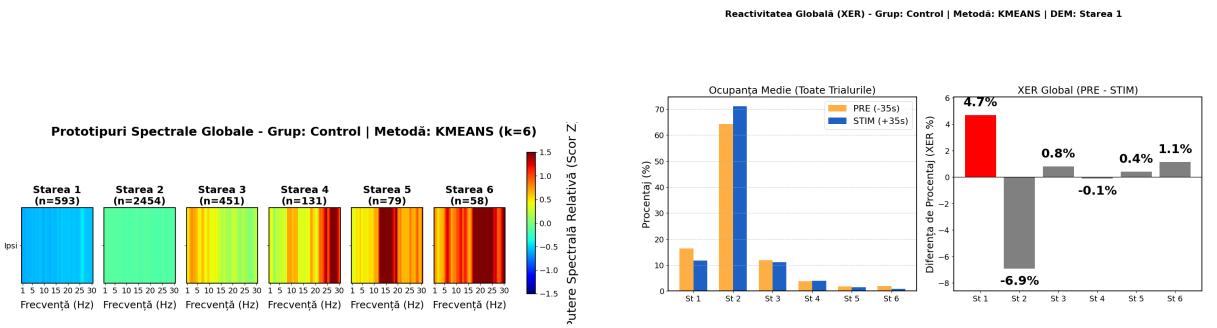


Figura 6.33: Prototipurile TSP, Ocupanța și Reactivitatea macrostărilor identificate: Grupul Control, Metoda K-Means

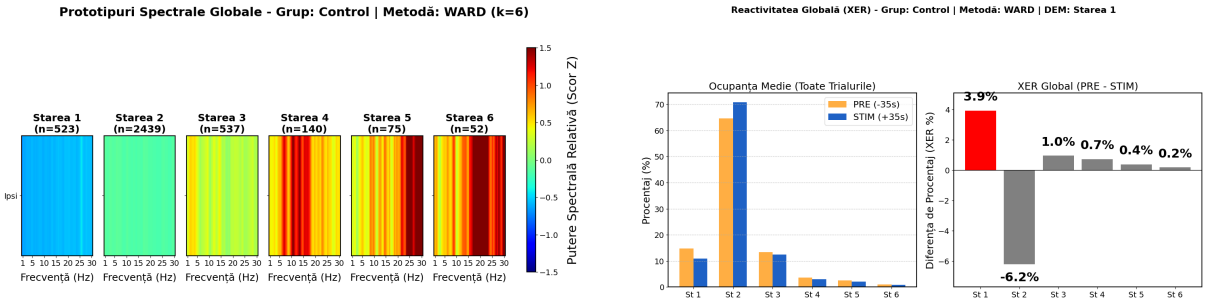


Figura 6.34: Prototipurile TSP, Ocupanța și Reactivitatea macrostărilor identificate: Grupul Control, Metoda Ward

6.2.4 Comparație reactivitate stare DEM pentru înregistrări individuale

În graficele cu bare din Figurile 6.35 și 6.36 se pot observa diferențele la nivelul reactivității macrostării identificate drept DEM, pentru fiecare înregistrare individuală, per grup experimental.

Se observă o diferență clară între grupurile experimentale, grupul ISO atingând valori are activității ridicate, cu o medie de 21.94%, comparativ cu grupul CHL, a cărui medie este de doar 7.04%. În cadrul grupului de control, media este aproape egală cu cea a grupului CHL, de 7%.

Aceste rezultate sugerează că subiecții din grupul ISO au tendința de a se afla într-o macrostare predominantă pre-stimul (DEM), iar în momentul stimulării ocupanța acesteia scade mult, comparativ cu celelalte grupuri. În grupul CHL apare un outlier (înregistrarea 2) care are un comportament asemănător cu cel observat pentru subiecții din grupul ISO (probabil din cauza unei stări de conștiență alterate cauzată de un alt factor extern, nu de CHL). În contrast, restul subiecților au un comportament mai asemănător celor din grupul de control, reactivitatea după stimulare având valori mult mai scăzute.

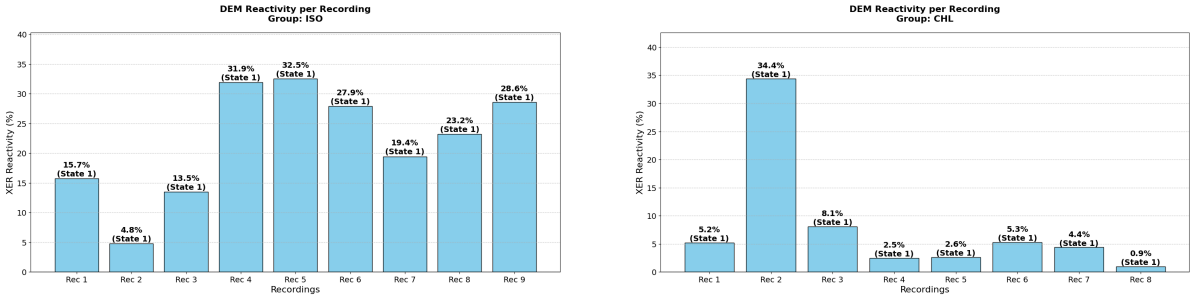


Figura 6.35: Reactivitatea stării DEM pentru înregistrările din Grupul ISO vs. Grupul CHL

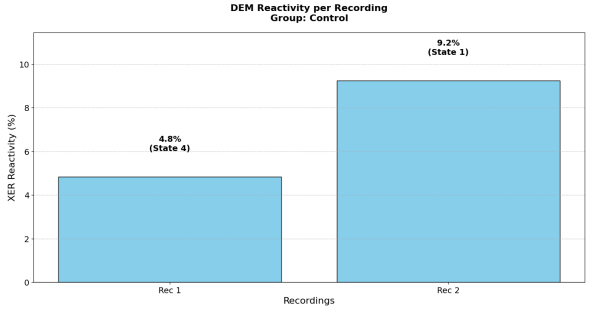


Figura 6.36: Reactivitatea stării DEM pentru înregistrările din grupul Control

6.2.5 Analiză prin Regresie liniară

Figura 6.37 ilustrează o analiză a nivelului de reactivitate a stării DEM, indusă de stimularea vizuală, în funcție de ocupanța stării înainte de stimul. Astfel, prin intermediul regresiei liniare se poate evalua dacă dinamica corticală ilustrată prin intremediul macrostărilor identificate reflectă o relație între starea inițială a creierul, a nivelului de conștiență și modul în care creierul răspunde la stimulare.

Se observă o relație de corelație între cele două variabile. Astfel, se observă ca panta este pozitivă în cazul tuturor grupurilor, indiferent de metoda de clusterizare folosită. Acest rezultat arată că o ocupanță mai mare a stării DEM pre-stimul determină o reactivitate mai ridicată în urma stimulării. Aceste observații sunt validate și de datele din Tabelul 6.1. Astfel, toate modelele sunt semnificative statistic ($p < 0.001$). Cele mai ridicate valori ale coeficientului de corelație apar pentru grupul ISO - Metoda K-means: $r = 0.92$, pantă $= 1.00$; Metoda Ward: $r = 0.88$, pantă $= 0.83$ -, ceea ce indică o relație puternică între Ocupanța pre-stimul a stării DEM și reactivitatea corticală. În schimb, celelate două grupuri, CHL - Metoda K-means: $r = 0.61$, pantă $= 0.51$; Metoda Ward: $r = 0.56$, pantă $= 0.33$ -, respectiv Control - Metoda K-means: $r = 0.71$, pantă $= 0.52$; Metoda Ward: $r = 0.73$, pantă $= 0.49$ -, prezintă corelații mai reduse, sugerând existența unei variabilități mai mari a reactivității cerebrale pentru diferite niveluri de ocupanță pre-stimul. Totodată, valorile mai ridicate ale pantei pentru grupul ISO sugerează că modificările la nivelul ocupanței post-stimul duc la variații mai ridicate ale răspunsului cortical.

Un alt aspect important este distribuția pe intervalele de ocupanță pre-stimul a stării DEM. Grupul ISO are doar valori în intervalul 40-60%, în timp ce subiecții din grupul de control au valori în intervalul 0-60%. Când vine vorba de grupul CHL, aceste valori se modifică în funcție de metoda de clusterizare utilizată, valorile fiind fie în intervalul 20-100% (metoda

K-means), fie 0-60% (metoda Ward). Astfel, această reprezentare a datelor validează din nou faptul că pentru grupul ISO, starea DEM este mai pronunțată pre-stimul față de cazul din celelalte grupuri, datorită stării mai pronunțate de inconștiență.

Astfel, este validat din punct de vedere fiziologic faptul că într-o stare de inconștiență indusă mai ridicată, ocupanța DEM este mai ridicată pre-stimul, iar prin valorile identificate prin regresia liniară, implicit și reactivitatea este mai ridicată, rezultate valabile pentru fiecare grup în mod individual.

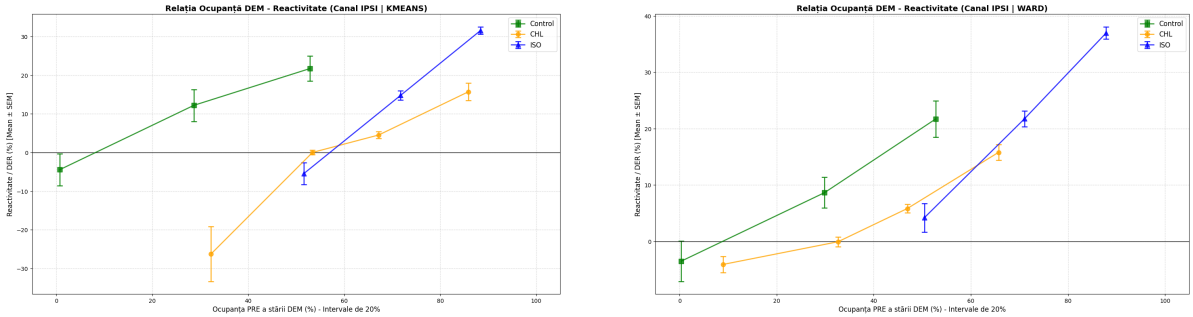


Figura 6.37: Analiza de regresie liniară pe intervale (bins) de 20% pentru validarea metodelor: K-Means (stânga) versus Ward (dreapta).

Grup	**Metodă**	**Distribuție pe intervale (nr. trialuri)**	**Ecuație de regresie (DER)**	r	p
Control	K-Means	0-20% (12), 20-40% (4), 40-60% (3)	$0.52 \cdot \text{DEM_PRE} - 4.36$	0.71	< 0.001
	Ward	0-20% (13), 20-40% (3), 40-60% (3)	$0.49 \cdot \text{DEM_PRE} - 3.88$	0.73	< 0.001
CHL	K-Means	20-40% (7), 40-60% (107), 60-80% (85), 80-100% (14)	$0.51 \cdot \text{DEM_PRE} - 28.43$	0.61	< 0.001
	Ward	0-20% (25), 20-40% (75), 40-60% (102), 60-80% (11)	$0.33 \cdot \text{DEM_PRE} - 9.51$	0.56	< 0.001
ISO	K-Means	40-60% (9), 60-80% (49), 80-100% (46)	$1.00 \cdot \text{DEM_PRE} - 57.30$	0.92	< 0.001
	Ward	40-60% (14), 60-80% (46), 80-100% (42)	$0.83 \cdot \text{DEM_PRE} - 36.44$	0.88	< 0.001

Tabelul 6.1: Statistici de regresie și distribuția trialurilor pe intervale de ocupanță pre-stimul (K-Means vs. Ward)

6.2.6 Discuții finale

În ansamblu, rezultatele din studiul 2 sugerează faptul că dinamica corticală ar putea fi ilustrată prin identificarea unor macrostări tipice, însă rezultatele sunt foarte sensibile la condițiile experimentale, incluzând aici și starea subiecților, cât și la deciziile luate din punct de vedere tehnic precum metoda de clusterizare utilizată și numărul de clustere impus.

Cu toate acestea, prin alegerea unui număr de clustere $k = 6$ și prin analiza în paralel a două metode de clusterizare (K-means și Ward), s-au putut trage câteva concluzii care au sens

și din punct de vedere neurofiziologic, dovedindu-se a fi o paradigmă care poate fi utilizată și îmbunătățită în viitoare studii.

7 Concluzii

Lucrarea de față a avut ca scop găsirea și optimizarea unor metode de analiză a datelor EEG în două contexte experimentale diferite, fiecare având particularități și cerințe specifice. Cu toate că cele două studii au avut la bază întrebări experimentale disincte și au avut în vedere aspecte diferite ale dinamicii corticale, am ales ca pentru ambele analiza să fie bazată pe metode de clusterizare, astfel încât structura internă a datelor să poată fi investigată, fără o impunere de constrângeri suplimentare prin modele supervizate sau desemnarea unor clase inițiale. Alegând această abordare, s-au putut evidenția anumite tipare în semnalele EEG și s-a putut evalua modul în care etapele de prepocesare alese influențează direct rezultatele finale.

Desfășurarea celor două studii în paralel mi-a oferit oportunitatea de a observa că orice problemă experimentală are nevoie de anumite adaptări specifice, cu toate că principiile de bază sunt comune, procesul ducând la soluții diverse. În acest sens, lucrarea nu a urmărit doar aplicarea unor paradigme existente, ci mai mult explorarea deferitelor posibilități de reprezentare și analizare a datelor EEG, cu scopul comun de a găsi abordări optime ale cerințelor, care să aibă rezultate relevante din punct de vedere fiziologic.

În acest sens, am identificat următoarele probleme și soluții.

În cadrul studiului bazat pe analiza răspunsului cortical la stimuli vizuali afectiv, problema inițială a fost de a găsi o formă cât mai eficientă de reprezentare a datelor în contextul experimentului, în care era necesară analiza per epocă, pentru fiecare răspuns individual la stimul, pentru a găsi variațiile din semnale care apar în funcție de tipul de imagine cu care s-a produs stimularea. În urma mai multor analize asupra metodelor, am ales să continui cu o reprezentare a semnalului EEG, mai exact a ERP-urilor apărute în fiecare epocă, în funcție de anumite trăsături extrase pentru fiecare semnal în parte. Această decizie a continuat cu o altă incertitudine, legată de modul optim de grupare a epocilor pentru a obține performanțe ridicate - per subiect, per canal, per regiune sau prin modificarea etichetelor. Cu toate că rezulatele nu au dus la o concluzie clară legată de modalitatea optimă de analiză, încercările efectuate au condus totuși la câteva concluzii importante, care pot fi luate în considerare în continuarea studiului. Astfel, s-a dovedit că reprezentarea în funcție de caracteristici este mult mai eficientă pentru acest caz de analiză per epocă și că preprocesarea reprezintă un pas esențial în analiza EEG, întrucât modul în care sunt eliminate zgomotul și artefactele poate influența semnificativ rezultatele. În plus, modul de grupare sau agregare a datelor, precum și modul în care sunt definite etichetele, pot avea un efect important și pot oferi informații valoroase legate de date și de noi moduri de a le vizualiza și interpreta.

Pe lângă toate acestea, un alt punct foarte important care a fost atins a fost cel de construire a unui BCI funcțional, capabil să vizualizeze semnalul în timp real, să îl înregistreze, prelucreze, segmenteze și să extragă caracteristicile, urmat de etapa de clusterizare, totul în timp real, printr-o paradigmă optimizată încât încărcarea computațională să nu depășească resursele disponibile ale calculatorului. Astfel, analiza se desfășoară fără întârzieri și cu rezultate obținute constant, pe baza cărora este realizată și analiza epocilor care continuă să fie înregistrate. Cu toate că metoda de clusterizare prezintă limitări, există o bază solidă, atât pentru analiza offline, cât și pentru cea în timp real, pentru următoarele etape ale studiului, dar și pentru cercetări viitoare.

În cadrul studiului axat pe analiza dinamicii activității cerebrale în condiții de alterare farmacologică a stării de conștiență, problema principală a fost la nivelul găsirii unor parametri sau a unei metode de clusterizare cât mai potrivite cu datele analizate. Cu toate că am întâmpinat dificultăți la identificarea unei variante optime pentru aceste decizii, alegerea lui $k = 6$ s-a dovedit a fiind una potrivită, ținând cont de rezultatele obținute. În același timp, faptul că nicuna dintre celel două metode de clusterizare nu s-a dovedit superioară celeilalte a dus desfășurarea întregii analize în paralel, ceea ce a fost benefic pentru analiza generală, întrucât rezultatele au fost validate reciproc, existând în mod constant asemănări între acestea și evidențiindu-se faptul că ambele metode sunt valide pentru acest tip de abordare. Astfel, cel mai important rezultat este dat de faptul că paradigma la care am ajuns în urma analizelor s-a dovedit a conduce către rezultate finale asemănătoare cu cele așteptate din punct de vedere fiziologic - atât faptul că starea DEM s-a dovedit a fiind starea cu cea mai mică energie și că un nivel indus mai mare de inconștiență conduce la un creier mai calm, aflat predominant în stare de repaus, cât și regresia realizată în final, prin care se evidențiază existența unei relații de corelație între nivel pre stimul de ocupanță a stării DEM și între modul în care reacționează creierul la prezența unui stimul.

7.1 Direcții viitoare

Direcțiile viitoare se diferențiază în funcție de cele două paradigme experimentale analizate.

În primul caz, direcțiile viitoare pe care le-aș vedea în acest sens sunt gruparea anumitor caracteristici în funcție de regiuni, pe baza informațiilor neurofiziologice existente în literatură, încercarea clusterizării în funcție de o singură dimensiune dintre cele trei VAD (valență, stimulare, dominanță), iar în urma rezultatelor individuale să se construiască o paradigmă care să funcționeze pe întreaga etichetă în același timp. După concretizarea unei metode offline, aceasta ar putea fi testată din nou în timp real, pe baza BCI-ului deja construit, precum și pe celălalt tip de stimuli, și anume stimulii arhitecturali.

În al doilea caz, ca direcții viitoare aș propune testarea aceleiași paradigme pe un set mai larg de date, dar și extinderea către alți subiecți din regnul animal și, ulterior, către oameni, pentru această analiză realizată pe un singur canal relevant modului de stimulare.

7.2 Concluzii generale

Lucrul pe cele două studii a adus atât provocări comune, cât și probleme de rezolvat sau decizii de luat, specifice fiecăruia dintre ele. În ansamblu, rezultatele au ilustrat faptul că analiza datelor EEG este un domeniu complex, iar cu toate că există o paradigmă comună pe baza căreia se construiește modul de lucru, fiecare studiu are particularități foarte specifice și vine cu diverse provocări care necesită varietăți la nivelul modurilor de reprezentare a datelor și a optimizărilor aduse metodelor consacrate de analiză. În plus, s-a pus în evidență faptul că, pe lângă construirea unor algoritmi performanți și eficienți, punctele esențiale care trebuie să fie atinse sunt validarea neurofiziologică și interpretabilitatea rezultatelor. Astfel, lucrarea oferă atât rezultate specifice cerințelor celor două paradigme experimentale, cât și un cadru în baza căruia se pot extinde și adapta cercetări viitoare.

8 Lista contribuțiilor personale

Proiect: Metode de preprocesare și învățare nesupervizată pentru analiza semnalelor electroencefalografice **Student:** Maria-Daria Bălăucă **Coordonator:** Conf. dr. ing. Andra-Elena Băltoiu		
	Activitate	**Durată [zile]**[1]
1	Discuții inițiale privind cadrul colaborării și direcția studiilor EEG	3
2	Discuții și ajustări metodologică în cadrul Studiului 1	3
3	Discuții și ajustări în cadrul Studiului 2	4
4	Documentare teoretică și analiză bibliografică pentru ambele studii	6
5	Participare la conferință aferentă Studiului 2	2
6	Colectarea datelor pentru Studiul 1	1
7	Evaluarea metodelor de preprocesare pentru Studiul 1	4
8	Segmentarea semnalelor EEG în epoci (date brute și după ICA) pentru Studiul 1	5
9	Analiza metodelor de clusterizare pe date brute în Studiul 1	4
10	Identificarea și evaluarea caracteristicilor pentru extragerea de trăsături	5
11	Evaluarea metodelor de clusterizare pe caracteristici extrase	3
12	Analiza strategiilor alternative de împărțire a datelor	2
13	Analiza setului de date pentru Studiul 2	4
14	Segmentarea epocilor pentru Studiul 2	2
15	Evaluarea metodelor de clusterizare pentru Studiul 2	5
16	Interpretarea rezultatelor din perspectivă neurofiziologică	4
17	Sincronizarea fluxurilor de date prin LSL	1
18	Dezvoltarea și testarea sistemului BCI	3
19	Redactarea lucrării de diplomă	7
20	Interpretarea și integrarea rezultatelor în documentație	5
Total		**72**

[1] Durata este exprimată în zile echivalente de lucru, adică 1 zi = 8 ore.

Mulțumiri

În final, doresc să îmi exprim recunoștiința față de membrii echipelor de cercetare cu care am colaborat pentru realizarea acestei lucrări. Le mulțumesc pentru încrederea acordată, sprijinul constant, discuțiile numeroase despre pașii următori și despre rezultatele intermediare. Nu aș fi putut să am o înțelegere variată asupra acestui domeniu complex fără ajutorul lor.

O parte importantă a acestei lucrări a fost realizată alături de exhipa laboratorului CINE-Tic, din Departamentului de Cercetare, Dezvoltare, Inovare, din cadrul Universității Naționale de Artă Teatrală și Cinematografică "I. L. Caragiale" București. Mulțumiri speciale revin către domnul Conf. univ. dr. Alexandru I. Berceanu, doamnei Cercet. șt. III dr. Alexandra Sofonea și domnului Prof. Pistol Constantin Augustin Dan, Facultatea de Fizică, Universitatea din București. Colaborarea cu dumnealor mi-a oferit oportunitatea de a vedea direct modul în care este gândit și implementat un experiment de cercetare, și de a înțelege aspectele practice legate de metodologia științifică.

O altă contribuție importantă a venit din partea echipei din cadrul Universității de Medicină și Farmacie "Carol Davila", București. Aș vrea să acord mulțumiri deosebite către domnul Prof. dr. Mihai Moldovan, doamnei Prof. dr. Ana Maria Zăgrean și domnului Dr. Vlad Morozan, pentru încrederea acordată de a-mi pune la dispoziție seturile de date utilizate, discuțiile detaliate despre partea neuro-fiziologică, dar și despre pașii de urmat. Totodată, le mulțumesc pentru oportunitatea de a participa la conferința "Meeting of the National Neuroscience Society of Romania 2026" (SNN 2026), în cadrul căreia am putut să îmi dezvolt și mai mult înțelegerea despre acest domeniu.

În ansamblu, experiențele acumulate în cadrul acest colaborări au avut un rol important atât în dezvoltarea lucrării de față, cât și în formarea mea, prin deschiderea acordată către cercetarea în domeniul neuroștiințelor.

Bibliografie

[1] Hafeez Ullah Amin și alții. „Single-Trial Extraction of Event-Related Potentials (ERPs) and Classification of Visual Stimuli by Ensemble Use of Discrete Wavelet Transform with Huffman Coding and Machine Learning Techniques“. În: *Journal of NeuroEngineering and Rehabilitation* 20.1 (2023), pag. 70.

[2] ANT Neuro. *eego™ rt*. Accessed: 19 June 2026. n.d. URL: https://www.ant-neuro.com/products/eego-rt.

[3] Linda Fiorini, Francesco Bossi și Francesco Di Gruttola. „EEG-Based Emotional Valence and Emotion Regulation Classification: A Data-Centric and Explainable Approach“. În: *Scientific Reports* 14.1 (2024), pag. 24046.

[4] Money Goyal, Mooninder Singh și Mandeep Singh. „Classification of Emotions Based on ERP Feature Extraction“. În: *2015 1st International Conference on Next Generation Computing Technologies (NGCT)*. IEEE. 2015, pag. 660–662.

[5] Niharika Gudikandula și alții. „Brain Computer Interface Based Emotion Recognition with Error Analysis and Challenges: An Interdisciplinary Review“. În: *Discover Applied Sciences* 7.8 (2025), pag. 857.

[6] Han Jia, Andrew H. Farkas și Dean Sabatinelli. „People, Places, and Things: The Impact of Scene Animacy on Emotional Modulation of the Early Posterior Negativity“. În: *Cognitive, Affective, & Behavioral Neuroscience* (2026), pag. 1–13.

[7] Lab Streaming Layer. *LabStreamingLayer's Documentation*. https://labstreaminglayer.readthedocs.io/. Accesat la 19 iunie 2026. 2025.

[8] N. G. Mathieu și alții. „Single-Trial ERP Classification of Emotional Processing“. În: *2013 6th International IEEE/EMBS Conference on Neural Engineering (NER)*. IEEE. 2013, pag. 101–104.

[9] MathWorks. *dtw - Distance Between Signals Using Dynamic Time Warping*. 2026. URL: https://www.mathworks.com/help/signal/ref/dtw.html.

[10] MathWorks. *kmeans - MATLAB Documentation*. https://www.mathworks.com/help/stats/kmeans.html.

[11] Vlad-Petru Morozan și alții. „Prolonged Antibiotic Exposure During Gestation Increases the Severity of Perinatal Asphyxia as Measured by EEG Reactivity in Rodents“. În: *Neurology international* 18.5 (2026), pag. 92.

[12] Vlad-Petru Morozan și alții. „THE DEFAULT EEG MACROSTATE REACTIVITY TO PHOTIC STIMULATION DEPENDS ON ANAESTHETIC DEPTH IN RATS“. În: *IBRO Neuroscience Reports* 15 (2023), S322–S323.

[13] LANG PJ. „International affective picture system (IAPS): affective ratings of pictures and instruction manual“. În: *Technical Report* (2005).

[14] Peter J Rousseeuw. „Silhouettes: a graphical aid to the interpretation and validation of cluster analysis“. În: *Journal of computational and applied mathematics* 20 (1987), pag. 53–65.

[15] Cosmin-Andrei Serban și alții. „A method to assess the default EEG macrostate and its reactivity to stimulation“. În: *Clinical Neurophysiology* 134 (2022), pag. 50–64.

[16] Ziana Syahputri, Machrani Adi Putri Siregar și alții. „Determining the optimal number of k-means clusters using the calinski harabasz index and krzanowski and lai index methods for groupsing flood prone areas in north sumatra“. În: *Sinkron: jurnal dan penelitian teknik informatika* 8.1 (2024), pag. 571–580.

[17] Muhammad Ali Syakur și alții. „Integration k-means clustering method and elbow method for identification of the best customer profile cluster“. În: *IOP conference series: materials science and engineering*. Vol. 336. 1. IOP Publishing. 2018, pag. 012017.

[18] Cosmin-Andrei Șerban și alții. „Towards an electroencephalographic measure of awareness based on the reactivity of oscillatory macrostates to hearing a subject's own name“. În: *European Journal of Neuroscience* 59.5 (2024), pag. 771–785.

[19] Sabin-Andrei Ţenea și alții. „The Co-Created City: Neuroadaptive Design for Healthy Environments“. În: *Intelligent Buildings International* (2025), pag. 1–17.